

**ANALISIS SENTIMEN PADA PLATFROM TWITTER
TERHADAP KETERLIBATAN INEOS SEBAGAI PEMILIK
BARU MANCHESTER UNITED MENGGUNAKAN MODEL
ROBERTA DAN VADER
SKRIPSI**

Diajukan untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Informatika



disusun oleh
FARHAN FATHURROZIQ
21.61.0213

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA
2026**

**ANALISIS SENTIMEN PADA PLATFROM TWITTER
TERHADAP KETERLIBATAN INEOS SEBAGAI PEMILIK
BARU MANCHESTER UNITED MENGGUNAKAN MODEL
ROBERTA DAN VADER**

SKRIPSI

untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Informatika



disusun oleh

FARHAN FATHURROZIQ

21.61.0213

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA
2026**

HALAMAN PERSETUJUAN

SKRIPSI

**ANALISIS SENTIMEN PADA PLATFROM TWITTER TERHADAP
KETERLIBATAN INEOS SEBAGAI PEMILIK BARU MANCHESTER
UNITED MENGGUNAKAN MODEL ROBERTA DAN VADER**

yang disusun dan diajukan oleh

FARHAN FATHURROZIQ

21.61.0213

telah disetujui oleh Dosen Pembimbing Skripsi
pada tanggal 20 Agustus 2025

Dosen Pembimbing,



Hanafi, S.Kom, M.Eng, Ph.D
NIK. 190302024

HALAMAN PENGESAHAN

SKRIPSI

**ANALISIS SENTIMEN PADA PLATFROM TWITTER
TERHADAP KETERLIBATAN INEOS SEBAGAI PEMILIK
BARU MANCHESTER UNITED MENGGUNAKAN MODEL
ROBERTA DAN VADER**

yang disusun dan diajukan oleh

FARHAN FATHURROZIQ

21.61.0213

Telah dipertahankan di depan Dewan Penguji
pada tanggal 20 Agustus 2025

Susunan Dewan Penguji

Nama Penguji

Tanda Tangan

Theopilus Bayu Sasongko, S.Kom., M.Eng.
NIK. 190302375

Ferian Fauzi Abdulloh, S.Kom., M.Kom.
NIK. 190302276

Hanafi, S.Kom., M.Eng., Ph.D.
NIK. 190302024



Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Komputer
Tanggal 20 Agustus 2025

DEKAN FAKULTAS ILMU KOMPUTER



Prof. Dr. Kusrini, M.Kom
NIK. 190302106

HALAMAN PERNYATAAN KEASLIAN SKRIPSI

Yang bertandatangan di bawah ini,

Nama mahasiswa : Farhan Fathurroziq
NIM : 21.61.0213

Menyatakan bahwa Skripsi dengan judul berikut:

ANALISIS SENTIMEN PADA PLATFROM TWITTER TERHADAP KETERLIBATAN INEOS SEBAGAI PEMILIK BARU MANCHESTER UNITED MENGGUNAKAN MODEL ROBERTA DAN VADER

Dosen Pembimbing : Hanafi, S.Kom, M.Eng, Ph.D

1. Karya tulis ini adalah benar-benar ASLI dan BELUM PERNAH diajukan untuk mendapatkan gelar akademik, baik di Universitas AMIKOM Yogyakarta maupun di Perguruan Tinggi lainnya.
2. Karya tulis ini merupakan gagasan, rumusan dan penelitian SAYA sendiri, tanpa bantuan pihak lain kecuali arahan dari Dosen Pembimbing.
3. Dalam karya tulis ini tidak terdapat karya atau pendapat orang lain, kecuali secara tertulis dengan jelas dicantumkan sebagai acuan dalam naskah dengan disebutkan nama pengarang dan disebutkan dalam Daftar Pustaka pada karya tulis ini.
4. Perangkat lunak yang digunakan dalam penelitian ini sepenuhnya menjadi tanggung jawab SAYA, bukan tanggung jawab Universitas AMIKOM Yogyakarta.
5. Pernyataan ini SAYA buat dengan sesungguhnya, apabila di kemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka SAYA bersedia menerima SANKSI AKADEMIK dengan pencabutan gelar yang sudah diperoleh, serta sanksi lainnya sesuai dengan norma yang berlaku di Perguruan Tinggi.

Yogyakarta, 20 Agustus 2025

Yang Menyatakan,

Meterai Asli
Rp 10.000,-



Farhan Fathurroziq

HALAMAN PERSEMBAHAN

Dengan rasa syukur kepada Allah SWT, skripsi ini penulis persembahkan kepada:

- 1) Allah SWT – sebagai penolong, pemberi kekuatan, dan sumber harapan dalam seluruh proses kehidupan dan penelitian ini. Tanpa pertolongan dan kasih karunia-Nya, penulis tidak akan mampu menyelesaikan skripsi ini.
- 2) Orang tua dan keluarga tercinta – atas motivasi, cinta, doa yang tak pernah putus, serta dukungan finansial yang diberikan. Kehadiran mereka memberikan inspirasi untuk terus bertumbuh dan memegang teguh prinsip hidup “Kerja keras, kerja tuntas.”
- 3) Diri penulis sendiri – atas semangat dan keteguhan hati untuk menuntaskan kewajiban ini, meskipun menghadapi keraguan, lelah, dan tantangan. Penulis bangga atas pencapaian yang berhasil diraih hingga dapat menuntaskan skripsi ini.
- 4) Teman-teman kelas 21BCI, teman-teman di Pontianak, sepupu dan teman seperjuangan – terima kasih atas tawa, kebahagiaan, nasihat, motivasi, serta dukungan yang diberikan. Kehadiran kalian telah menemani dan membantu penulis dalam proses penyelesaian skripsi.
- 5) Dosen Pembimbing – atas bimbingan, arahan, dan kesabaran yang diberikan selama proses penelitian ini, sehingga penulis dapat menyelesaikan skripsi dengan baik.
- 6) Guru dan Dosen – mulai dari tingkat SD, SMP, SMA, hingga perguruan tinggi, atas ilmu, moral, dan adab yang diajarkan sehingga penulis dapat menempuh pendidikan hingga tahap ini.
- 7) Penulis buku dan pembuat konten bertema pengembangan diri – yang telah menciptakan karya-karya inspiratif dan memotivasi penulis untuk terus berproses menjadi pribadi yang lebih baik.
- 8) Bagi teman yang belum menyelesaikan studi kuliahnya. Skripsi ini saya persembahkan agar dapat memotivasi segera menyelesaikannya studinya.

Semua pihak di atas telah menjadi bagian penting dari proses yang Penulis lalui. Tanpa kalian, penelitian ini tidak akan mencapai titik akhir seperti saat ini.

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan penyusunan Skripsi dengan judul:

ANALISIS SENTIMEN PADA PLATFROM TWITTER TERHADAP KETERLIBATAN INEOS SEBAGAI PEMILIK BARU MANCHESTER UNITED MENGGUNAKAN MODEL ROBERTA DAN VADER

Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan studi pada Program Sarjana di Universitas Amikom Yogyakarta. Dengan selesainya skripsi ini, penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. M. Suyanto, MM selaku Rektor Universitas Amikom Yogyakarta.
2. Bapak Hanif Al Fatta, S.Kom., M.Kom. selaku Dekan Fakultas Ilmu Komputer.
3. Ibu Windha Mega Pradnya D, M.Kom. selaku Ketua Program Studi S1 Informatika.
4. Bapak Hanafi, S.Kom, M.Eng, Ph.D selaku dosen pembimbing yang telah memberikan bimbingan, arahan, serta semangat selama proses penelitian hingga penulisan skripsi ini.

Penulis juga menyampaikan terima kasih kepada seluruh pihak yang telah membantu secara langsung maupun tidak langsung dalam penyelesaian skripsi ini. Penulis menyadari bahwa penyusunan skripsi ini masih memiliki banyak kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi kesempurnaan skripsi ini. Penulis berharap karya ini dapat memberikan manfaat bagi semua pihak yang membaca dan membutuhkannya.

Yogyakarta, 22 September 2025

Penulis

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERSETUJUAN	ii
HALAMAN PENGESAHAN	iii
HALAMAN PERNYATAAN KEASLIAN SKRIPSI	iv
HALAMAN PERSEMBAHAN	v
KATA PENGANTAR	vi
DAFTAR ISI	vii
DAFTAR TABEL	x
DAFTAR GAMBAR	xi
DAFTAR LAMBANG DAN SINGKATAN	xii
DAFTAR ISTILAH	xiii
INTISARI	xvi
<i>ABSTRACT</i>	xvii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	5
1.5 Manfaat Penelitian	5
1.5.1 Manfaat Teoretis	6
1.5.2 Manfaat Praktis	6
1.6 Sistematika Penulisan	6
BAB II TINJAUAN PUSTAKA	9

2.1	Studi Literatur	9
2.2	Dasar Teori	15
2.3	Natural Language Processing (NLP)	15
2.3.1	Jenis-Jenis Natural Language Processing (NLP)	16
2.3.2	Faktor-Faktor Yang Mempengaruhi NLP	18
2.4	Analisis Sentimen	19
2.5	Lexicon-Based Approach	20
2.6	Machine Learning Approach	20
2.7	VADER & Lexicon-Based Approach Model	21
2.8	RoBERTa & Machine Learning Approach Model	22
2.8.1	Penghitungan Sentiment Score dengan Model RoBERTa	24
2.9	Logistic Regression sebagai Meta-Classifer pada Ensemble Stacking	26
BAB III METODE PENELITIAN		28
3.1	Objek Penelitian	28
3.2	Alur Penelitian	28
3.2.1	Pengumpulan Data	29
3.2.2	Preprocessing, Splitting and Balancing Data	30
3.2.3	Model Preparation	32
3.2.4	Fine-tuning RoBERTa model	33
3.2.5	Optimizing VADER threshold	34
3.2.6	Meta-classification model	35
3.2.7	Evaluate model	36
3.2.8	Analyze Manchester United fan sentiment	39
3.3	Alat dan Bahan	39
3.3.1	Alat	39

3.3.2	Bahan	40
BAB IV HASIL DAN PEMBAHASAN		42
4.1	Gambaran Umum	42
4.2	Pengumpulan data	42
4.2	Eksplorasi Data	44
4.2.1	Eksplorasi Data Pelatihan	44
4.2.2	Eksplorasi Data Tweet	48
4.3	Hasil Evaluasi Model RoBERTa	50
4.4	Hasil Evaluasi Model VADER	51
4.5	Hasil Evaluasi Model Meta-Classification	51
4.6	Perbandingan ketiga model	52
4.7	Analisis Sentimen Manchester United terhadap Keterlibatan INEOS	54
4.7.1	Analisis sentimen positif	55
4.7.2	Analisis sentimen netral	56
4.7.3	Analisis sentimen negatif	58
BAB V PENUTUP		60
5.1	Kesimpulan	60
5.2	Saran	60
REFERENSI		62

DAFTAR TABEL

Tabel 2. 1 Keaslian Penelitian	13
Tabel 3. 1 Perbandingan data training awal dan setelah pembagian	31
Tabel 3. 2 Pembagian data balancing	32
Tabel 3. 3 Jumlah data train atau input meta-classfier model	36
Tabel 3. 4 Jumlah data uji meta-classifer model	36
Tabel 4. 1 Evaluasi fine-tuning RoBERTa pada 3 versi dataset	50
Tabel 4. 2 Perbandingan threshold default dan dioptimalkan VADER	51
Tabel 4. 3 Hasil evaluasi meta-classifier model	51
Tabel 4. 4 Metrik ketiga model	52
Tabel 4. 5 Perbandingan prediksi model terhadap sentimen Manchester United	54

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur transformers	23
Gambar 3. 1 Alur Penelitian	29
Gambar 3. 2 Potongan kode optimasi threshold VADER	35
Gambar 4. 1 Hasil Jumlah data training yang didapatkan	44
Gambar 4. 2 Distribusi Label Sentimen Data Pelatihan	45
Gambar 4. 3 Distribusi panjang tweet per kelas sentimen	46
Gambar 4. 4 WordCloud data pelatihan	47
Gambar 4. 5 Persebaran distribusi data tweet	49
Gambar 4. 6 WordCloud data tweet	50
Gambar 4. 7 Confusion Matrix ketiga model	53
Gambar 4. 8 Visualisasi perbandingan prediksi model terhadap sentimen Manchester United	55
Gambar 4. 9 Visualisasi Wordcloud Positive sentimen data tweet	56
Gambar 4. 10 Visualisasi Wordcloud Neutral sentimen data tweet	57
Gambar 4. 11 Visualisasi Wordcloud Negative sentimen data tweet	58

DAFTAR LAMBANG DAN SINGKATAN

NLP	Natural Language Processing
RoBERTa	Robustly Optimized BERT Pretraining Approach
VADER	Valence Aware Dictionary and Sentiment Reasoner
SVM	Support Vector Machines
EDA	Exploratory Data Analysis
TF-IDF	Term Frequency - Inverse Document Frequency
ROS	Random Over Sampling
RUS	Random Under Sampling
STT	Speech-to-Text
TTS	Text-to-Speech
API	Application Programming Interface
TPU	Tensor Processing Unit
GPU	Graphics Processing Unit
ML	Machine Learning
AI	Artificial Intelligence

DAFTAR ISTILAH

Natural Language Processing	Bidang kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia.
Analisis Sentimen	Proses mengklasifikasikan teks menjadi kategori opini (positif, negatif, netral).
RoBERTa	Model NLP berbasis transformer yang dioptimalkan dari BERT untuk pemahaman konteks bahasa yang lebih baik.
VADER	Model berbasis leksikon yang dirancang untuk analisis sentimen pada teks pendek seperti tweet.
Lexicon-Based Approach	Pendekatan analisis sentimen menggunakan kamus kata yang memiliki nilai polaritas.
Machine Learning Approach	Pendekatan analisis sentimen menggunakan algoritma pembelajaran mesin untuk mengenali pola dari data latih.
Meta-Classifer	Model yang menggabungkan hasil prediksi dari beberapa model (base models) untuk menghasilkan keputusan akhir yang lebih baik.
Logistic Regression	Algoritma klasifikasi yang digunakan sebagai meta-classifier untuk ensemble stacking dalam penelitian ini.
Precision	Rasio prediksi positif yang benar dibandingkan dengan seluruh prediksi positif.
Recall	Rasio prediksi positif yang benar dibandingkan dengan seluruh data positif sebenarnya.

F1-Score	Rata-rata harmonis antara precision dan recall, digunakan untuk mengukur keseimbangan keduanya.
Accuracy	Proporsi prediksi yang benar dibandingkan seluruh data.
Oversampling	Teknik penyeimbangan data dengan menambah jumlah sampel kelas minoritas.
Undersampling	Teknik penyeimbangan data dengan mengurangi jumlah sampel kelas mayoritas.
Stratified Sampling	Teknik pembagian data dengan mempertahankan proporsi kelas pada setiap subset.
Preprocessing	Tahap awal pembersihan dan penyiapan data teks sebelum dianalisis atau diproses model.
Tokenisasi	Proses memecah teks menjadi unit kecil (token) agar dapat diproses oleh model.
Fine-Tuning	Proses melatih ulang model pralatih (seperti RoBERTa) pada dataset khusus agar lebih sesuai dengan domain data.
Threshold Optimization	Penyesuaian nilai ambang (threshold) pada model seperti VADER untuk meningkatkan akurasi klasifikasi.
Confusion Matrix	Matriks yang menunjukkan jumlah prediksi benar dan salah dari model untuk setiap kelas.
WordCloud	Representasi visual kata yang sering muncul dalam dataset, dengan ukuran kata sesuai frekuensinya.
Tweet-Harvest	Alat yang digunakan untuk melakukan crawling data tweet dari Twitter.

Open-Access

Sistem publikasi yang memungkinkan artikel/jurnal dapat diakses secara gratis oleh siapa pun tanpa hambatan berbayar.

INTISARI

Keterlibatan INEOS dalam kepemilikan Manchester United menjadi topik yang banyak diperbincangkan oleh publik, khususnya di media sosial seperti Twitter. Dinamika opini publik yang muncul menimbulkan kebutuhan untuk menganalisis sentimen penggemar terhadap perubahan tersebut. Permasalahan yang diangkat dalam penelitian ini adalah bagaimana sentimen terhadap keterlibatan INEOS sebagai pemilik baru Manchester United berdasarkan data yang diungkap melalui platform Twitter, serta bagaimana model-model Natural Language Processing (NLP) dapat digunakan untuk mengevaluasi sentimen tersebut secara akurat.

Penelitian ini menggunakan pendekatan NLP dengan dua model utama. RoBERTa, sebagai model berbasis pembelajaran mesin, dan VADER, sebagai model berbasis leksikon. Data diambil melalui proses crawling menggunakan *Tweet-Harvest* dan dilakukan preprocessing, splitting, serta balancing. RoBERTa dilakukan fine-tuning terhadap data latih berlabel, sedangkan VADER dioptimalkan melalui penyesuaian threshold. Hasil prediksi keduanya kemudian dikombinasikan ke dalam model meta-classifier berbasis Logistic Regression untuk meningkatkan akurasi klasifikasi.

Hasil evaluasi menunjukkan bahwa model gabungan RoBERTa dan VADER memiliki performa terbaik dengan akurasi 71% dan F1-score 71%, mengungguli performa masing-masing model secara terpisah. Model gabungan juga menunjukkan kemampuan yang lebih seimbang dalam mengklasifikasikan sentimen positif, netral, dan negatif. Penelitian ini berkontribusi dalam pengembangan metode hybrid untuk analisis sentimen berbasis media sosial, dan dapat dimanfaatkan oleh praktisi komunikasi, analis media, maupun stakeholder klub untuk memahami persepsi publik secara lebih mendalam. Rekomendasi selanjutnya adalah penggunaan dataset multimodal dan eksplorasi teknik ensemble lanjutan.

Kata kunci: Analisis Sentimen, RoBERTa, VADER, Meta-classifier, Logistic Regression.

ABSTRACT

INEOS' involvement in the ownership of Manchester United has become a hot topic of discussion among the public, especially on social media platforms such as Twitter. The dynamics of public opinion that have emerged necessitate an analysis of fan sentiment toward this change. The issue addressed in this study is how sentiment toward INEOS involvement as the new owner of Manchester United is reflected in data revealed through the Twitter platform, as well as how Natural Language Processing (NLP) models can be used to accurately evaluate such sentiment.

This study employs an NLP approach with two main models: RoBERTa, a machine learning-based model, and VADER, a lexicon-based model. Data was collected through a crawling process using Tweet-Harvest and underwent preprocessing, splitting, and balancing. RoBERTa was fine-tuned on labeled training data, while VADER was optimized through threshold adjustment. The prediction results of both models were then combined into a Logistic Regression-based meta-classifier model to improve classification accuracy.

The evaluation results showed that the combined RoBERTa and VADER model had the best performance with an accuracy of 71% and an F1-score of 71%, outperforming the performance of each model separately. The combined model also demonstrated more balanced capabilities in classifying positive, neutral, and negative sentiments. This research contributes to the development of hybrid methods for social media-based sentiment analysis and can be utilized by communication practitioners, media analysts, and club stakeholders to gain a deeper understanding of public perception. Further recommendations include the use of multimodal datasets and the exploration of advanced ensemble techniques.

Keyword: *Sentiment analysis, RoBERTa, VADER, Meta-classifier, Logistic Regression.*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sepak bola adalah salah satu olahraga yang sangat disukai rakyat Indonesia, menurut data survei dari [1] dari seluruh responden Indonesia sebanyak 69% menyukai sepak bola. Bahkan dampak yang diberikan beberapa pemain besar seperti Cristiano Ronaldo dan Leonel Messi banyak menginspirasi seseorang untuk menjadi seperti idola mereka tersebut. Dengan segala perkembangannya sepak bola berubah dari industri hiburan semata menjadi bisnis yang sangat menguntungkan bagi pemiliknya [2]. Peran penting dari pemilik dan sponsor klub sangat dibutuhkan untuk menjaga atau meningkatkan reputasi klub agar klub dapat mengikuti turnamen besar dan tetap berada di puncak liga teratas di liga.

Dalam 5 tahun kebelakang beberapa klub telah berpindah tangan dari pemegang sebelumnya. Tentu saja perpindahan tangan kepemilikan memiliki dampak seperti contoh kasus klub Chelsea FC yang pada periode tahun 2021-2022 baru saja memenangkan piala *UEFA Champions League* (UCL). Setelah berpindah kepemilikan dari Roman Abramovich ke tangan Todd Boehly [3] pada tahun berikutnya mengalami kemerosotan menjadi peringkat 12 yang pada tahun sebelumnya peringkat 3 di *English Premier League* (EPL). Ada juga contoh kasus klub yang meningkat setelah berpindah kepemilikan yaitu Manchester City seperti dari jurnal [4] menyatakan Manchester City yang beberapa tahun terakhir ini menjadi fokus utama dari pemodal Arab, mencapai peraih yang sangat memuaskan yakni berhasil mendapatkan *Treble Winners* (menjuarai 3 piala major dalam satu musim) di periode tahun 2022-2023. Manchester United yang merupakan tetangga dari Manchester City juga mengalami hal yang sama yakni perpindahan kepemilikan. Kepemilikan klub Manchester United pada saat ini dipegang oleh Sir Jim Ratcliffe yakni orang yang memiliki perusahaan besar INEOS [5].

Sepak bola adalah industri yang didorong oleh emosi. Industri ini menarik berbagai pihak dan tidak hanya membawa popularitas, pendapatan besar yang dihasilkan dari penggemar, perusahaan, dan pengiklan [6]. Oleh karena itu,

Pemangku kepentingan termasuk didalamnya pemilik klub dapat memengaruhi pendapat sentimen penggemar, perusahaan, dan pengiklan melalui keputusan yang dilakukan mereka. Pendapat sentimen yang buruk terhadap klub dapat menimbulkan kerugian pada pihak pemilik, sponsor, dan pemangku kepentingan lain di klub baik dari segi finansial dan reputasi klub dan sponsornya. Di era yang sekarang ini banyaknya media platform sosial media memudahkan masyarakat untuk menyampaikan opininya [7]. Dalam penelitian ini data opini atau sentimen publik pada media platform twitter digunakan untuk melakukan analisis sentimen.

Dalam menganalisis opini dan sentimen di media sosial, teknologi machine learning dan *Natural Language Processing* (NLP) memainkan peran yang sangat penting. *NLP* merupakan salah satu cabang ilmu *Artificial Intelligence* (AI) yang berfokus pada pengolahan bahasa natural [8]. Dalam konteks ini, NLP digunakan untuk memproses dan menganalisis teks yang diposting di media sosial. Dengan memanfaatkan teknik NLP, opini penggemar sepak bola di Twitter dapat dikategorikan sebagai sentimen positif, negatif, atau netral. Dalam penelitian ini untuk mengklasifikasikan teks berdasarkan sentimen yang diungkapkan model *VADER* (*Valence Aware Dictionary and sEntiment Reasoner*) dan *RoBERTa* (*Robustly optimized BERT approach*) digunakan. *VADER* adalah model berbasis aturan yang khusus dirancang untuk analisis sentimen teks pendek di media sosial. Model *VADER* menetapkan skor polaritas antara -1 hingga +1 yang dikategorikan menjadi Positif, Netral, dan Negatif. *RoBERTa*, yang merupakan pengembangan dari model *BERT* dengan lebih banyak data prelatihan, mampu menangkap konteks lebih dalam dan memberikan hasil yang lebih akurat dalam analisis sentimen [9].

Menurut penelitian [10], pendekatan kombinasi *VADER* dan *RoBERTa* memberikan hasil yang signifikan dalam analisis sentimen karena masing-masing metode memiliki keunggulan tersendiri. *VADER*, sebagai model berbasis leksikon, sangat efektif dalam mengukur sentimen pada teks pendek seperti tweet, dengan memberikan skor polaritas yang langsung dapat diklasifikasikan sebagai positif, netral, atau negatif. Sedangkan *RoBERTa* yang merupakan pengembangan dari *BERT*, memiliki kemampuan mendalam untuk memahami konteks dalam teks

dengan data prapelatihan yang lebih luas, menghasilkan akurasi yang lebih tinggi dalam pengklasifikasian sentimen. Penelitian tersebut menunjukkan bahwa kombinasi kedua metode ini dapat menangani tantangan analisis sentimen yang kompleks, terutama dalam pengolahan data dari platform media sosial. Oleh karena itu, pendekatan ini relevan dan sesuai untuk digunakan dalam penelitian ini, yang bertujuan untuk memahami sentimen keterlibatan INEOS sebagai pemilik baru Manchester United berdasarkan data yang diambil dari platform Twitter.

Untuk mendapatkan opini dengan skala global, data yang diambil dari Twitter akan dibatasi pada tweet berbahasa Inggris. Hal ini dilakukan karena bahasa Inggris adalah lingua franca yang digunakan oleh penggemar sepak bola dari berbagai negara. Meskipun ini mungkin mengabaikan opini dari pengguna yang tidak berbahasa Inggris, pendekatan ini memungkinkan penelitian mencakup opini yang lebih luas dan lebih beragam secara geografis. Pengambilan data ini juga memastikan bahwa analisis dapat dilakukan dengan lebih konsisten, mengingat bahasa Inggris memiliki banyak sumber daya NLP yang sudah matang dan tersedia.

Penelitian ini bertujuan untuk mengetahui persebaran sentimen terhadap keterlibatan INEOS sebagai pemilik baru Manchester United. Serta menguji kinerja dua model algoritma, yaitu VADER dan RoBERTa, dalam analisis sentimen. Dengan menganalisis data dari Twitter, penelitian ini berusaha memahami bagaimana keterlibatan INEOS memengaruhi pandangan dan perasaan penggemar terhadap klub. Fokus pada pengujian kedua model ini diharapkan dapat memberikan gambaran yang lebih komprehensif mengenai efektivitas pendekatan berbasis leksikon dan berbasis pembelajaran mendalam dalam mengolah data sentimen. Hasil dari penelitian ini diharapkan dapat memberikan wawasan berharga bagi pemangku kepentingan di Manchester United dalam mengelola hubungan dengan penggemar, menjaga reputasi klub, dan mengevaluasi keandalan model-model analisis sentimen.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini berusaha menjawab beberapa pertanyaan utama berikut:

- 1) Bagaimanakah kinerja model RoBERTa dan VADER dalam analisis sentimen dari dataset berlabel yang digunakan?
- 2) Bagaimana persebaran sentimen dari masuknya INEOS sebagai pemilik baru Manchester United yang diungkapkan melalui platform Twitter?
- 3) Bagaimana pola sentimen (positif, netral, negatif) pengguna Twitter terhadap keterlibatan INEOS sebagai pemilik baru Manchester United?

1.3 Batasan Masalah

Untuk mengoptimalkan penelitian berikut adalah beberapa batasan yang ditetapkan:

Batasan Data:

- 1) Data yang diambil pada penelitian ini hanya menggunakan data berupa tweet dari platform Twitter yang diambil mulai dalam rentang Desember 2023 hingga Desember 2024
- 2) Data tweet yang diambil hanya yang menggunakan bahasa Inggris
- 3) Data yang digunakan terbatas pada tweet yang mengandung kata kunci spesifik seperti “Manchester United”, “INEOS”, dan beberapa hal terkait lainnya.
- 4) Dataset yang digunakan untuk mengevaluasi model terbatas pada dataset *tweet_eval/sentiment* pada platform huggingface

Batasan Metodologi:

- 1) Teknik analisis yang digunakan hanya terbatas pada Natural Language Processing (NLP) dengan metode analisis sentimen
- 2) Model yang digunakan pada penelitian hanya mencakup model RoBERTa dan VADER
- 3) Matriks yang digunakan dalam mengevaluasi model menggunakan *accuracy*, *F1-score*, *recall*, dan *precision*

Batasan Fokus Studi:

- 1) Penelitian ini hanya berfokus pada sentimen keterlibatan INEOS sebagai pemilik baru klub Manchester United pada platform twitter, tanpa mempertimbangkan faktor eksternal lainnya
- 2) Penelitian ini tidak mencakup analisis tim, taktik permainan, dan hal lainnya selain sentimen yang beredar pada platform Twitter terkait Manchester United dan INEOS.

Batasan Hasil Penelitian:

- 1) Penelitian ini berfokus pada analisis data sentimen dan tidak bertujuan untuk memvalidasi generalisasi hasil penggabungan model terhadap data lain.
- 2) Penelitian ini tidak mengevaluasi dampak langsung keterlibatan INEOS terhadap kinerja bisnis atau keuangan klub

1.4 Tujuan Penelitian

Penelitian ini memiliki beberapa tujuan yang dijabarkan sebagai berikut:

- 1) Menganalisis sentimen terhadap keterlibatan INEOS sebagai pemilik baru Manchester United menggunakan data dari platform Twitter.
- 2) Mengevaluasi performa model RoBERTa dan VADER dalam analisis sentimen, termasuk membandingkan *accuracy*, *precision*, *recall*, dan *F1-score* antara kedua model tersebut.
- 3) Mengembangkan metode kombinasi hasil analisis sentimen dari RoBERTa dan VADER untuk meningkatkan kualitas dan keandalan interpretasi sentimen secara keseluruhan.
- 4) Memberikan wawasan yang lebih mendalam mengenai bagaimana keterlibatan INEOS memengaruhi persepsi penggemar, yang dapat digunakan sebagai referensi bagi manajemen klub atau pihak terkait.

1.5 Manfaat Penelitian

Penelitian ini berusaha untuk memberikan kontribusi baik secara teoritis maupun praktis, yang bermanfaat bagi perkembangan teknologi *Machine Learning*

(ML) dalam pemrosesan bahasa alami (NLP) dengan memanfaatkan *Artificial Intelligence* (AI).

1.5.1 Manfaat Teoretis

- 1) Penelitian ini berkontribusi pada pengembangan studi analisis sentimen, khususnya dalam penerapan model berbasis Natural Language Processing (NLP) seperti RoBERTa dan pendekatan lexicon-based seperti VADER.
- 2) Hasil penelitian dapat menjadi rujukan bagi penelitian lanjutan yang mengeksplorasi kombinasi berbagai model analisis sentimen untuk meningkatkan akurasi serta efisiensi pengolahan data teks.
- 3) Penelitian ini juga memperkaya kajian akademik mengenai dampak keterlibatan perusahaan (seperti INEOS) terhadap opini publik dalam konteks olahraga profesional.

1.5.2 Manfaat Praktis

- 1) Bagi Manchester United atau pihak terkait Penelitian ini memberikan wawasan mendalam terkait persepsi dan sentimen penggemar terhadap keterlibatan INEOS. Wawasan ini dapat digunakan untuk mendukung pengambilan keputusan strategis dalam aspek komunikasi, pemasaran, atau kebijakan klub.
- 2) Bagi peneliti masa depan Studi ini dapat dijadikan referensi untuk pengembangan lebih lanjut dalam analisis sentimen, khususnya pada pengolahan data dari media sosial untuk memahami opini publik. Peneliti selanjutnya dapat memperluas penerapan metode ini ke kasus lain dalam bidang olahraga atau sektor yang berbeda.
- 3) Bagi praktisi teknologi Hasil penelitian ini dapat digunakan oleh pengembang perangkat lunak atau platform analitik untuk menciptakan solusi yang lebih efektif dalam menganalisis sentimen publik berbasis data media sosial.

1.6 Sistematika Penulisan

Skripsi ini memiliki sistematika penulisan yang terbagi menjadi lima bab

yang memaparkan tahapan penelitian. Mulai dari latar belakang hingga kesimpulan dan saran. Garis besar dari penelitian ini ialah sebagai berikut :

BAB I PENDAHULUAN

Bab ini menjelaskan latar belakang masalah yang menjadi dasar penelitian, rumusan masalah, tujuan penelitian, manfaat penelitian, serta batasan masalah. Peneliti juga memaparkan pentingnya analisis sentimen dalam memahami pandangan opini publik terhadap keterlibatan INEOS sebagai pemilik baru Manchester United.

BAB II TINJAUAN PUSTAKA

Bab ini berisi kajian pustaka dan menguraikan landasan teori yang relevan dengan penelitian tentang sentiment analysis, algoritma atau model yang digunakan (RoBERTa dan VADER), dasar teori terkait Natural Language Processing (NLP), studi literatur terkait keterlibatan perusahaan dalam dunia sepak bola dan penelitian terdahulu yang serupa.

BAB III METODE PENELITIAN

Bab ini menjelaskan secara rinci metode yang digunakan dalam penelitian. Bab ini mencakup tinjauan umum objek penelitian yang menjelaskan latar belakang keterlibatan INEOS dan konteks Manchester United. Proses pengumpulan data dijelaskan melalui cara pengambilan data Twitter, termasuk kata kunci, periode waktu, dan alat yang digunakan. Selain itu, dijelaskan langkah-langkah *preprocessing* data dan juga memaparkan teknik analisis yang digunakan, baik secara statistik maupun dengan machine learning, serta menyertakan rancangan penelitian berupa diagram atau alur kerja penelitian untuk memberikan gambaran sistematis proses penelitian.

BAB IV HASIL DAN PEMBAHASAN

memuat hasil penelitian yang disajikan dalam bentuk analisis data, seperti distribusi sentimen positif, negatif, dan netral terhadap keterlibatan INEOS. Bab ini juga mencakup pembahasan yang melibatkan interpretasi hasil, diskusi terkait pola sentimen yang muncul, serta keterkaitannya dengan teori atau studi terdahulu.

Peneliti menjelaskan implikasi hasil penelitian terhadap manajemen klub atau persepsi publik.

BAB V PENUTUP

Bab ini menyajikan kesimpulan dari hasil penelitian serta menjawab tujuan yang telah dirumuskan. Bab ini juga memberikan saran, baik untuk penelitian lanjutan maupun bagi pihak-pihak yang berkepentingan, seperti Manchester United atau INEOS.

BAB II

TINJAUAN PUSTAKA

2.1 Studi Literatur

Tinjauan pustaka merupakan bagian penting dari penelitian ini yang memberikan landasan teoritis sebagai dasar untuk memahami dan menganalisis data. Bab ini melanjutkan pembahasan dari Bab I, yang menyoroti pentingnya analisis sentimen untuk memahami respons penggemar terhadap keterlibatan INEOS di Manchester United. Dalam bab ini, teori-teori yang relevan dijelaskan, termasuk konsep dasar analisis sentimen, teknologi *Natural Language Processing* (NLP), serta model yang digunakan. Peneliti menyadari pentingnya landasan teori dalam memperkuat analisis dan relevansi penelitian. Oleh karena itu, tinjauan pustaka ini dibuat untuk menjembatani antara teori, penelitian terdahulu, dan fokus penelitian. Peneliti berharap relevansi dan pendekatan yang diambil dalam penelitian ini dapat dipahami oleh pembaca.

Dibahasa pada jurnal [7] media sosial telah menjadi sumber data penting untuk analisis sentimen, terutama dalam konteks isu-isu yang bersifat emosional seperti olahraga. Platform seperti Twitter dan Instagram menyediakan akses real-time ke opini publik, Hasil dari penelitian tersebut yang digunakan untuk analisis sentimen terhadap kinerja PSSI menggunakan data dari komentar instagram menunjukkan efektivitas algoritma *Support Vector Machine* (SVM) dalam mengklasifikasikan sentimen dengan akurasi hingga 94,36%. Hal ini membuktikan bahwa data dari media sosial memberikan wawasan yang kaya tentang persepsi masyarakat terhadap organisasi atau subjek tertentu. Dalam konteks penelitian ini, data dari twitter digunakan untuk menganalisis sentimen keterlibatan INEOS sebagai pemilik baru Manchester United. Media sosial tidak hanya menyediakan data dalam jumlah besar, tetapi juga memungkinkan akses ke opini dalam bentuk teks pendek seperti tweet. Hal ini sangat relevan untuk diterapkan dengan model NLP modern seperti VADER dan RoBERTa. Dengan demikian, analisis sentimen berbasis media sosial dapat memberikan gambaran yang lebih komprehensif mengenai opini publik.

Pada penelitian [11] terkait analisis ulasan produk Uniqlo, metode analisis sentimen digunakan untuk mengevaluasi opini pelanggan terhadap berbagai produk yang ditawarkan. Dengan memanfaatkan teknik *text mining* dan metode klasifikasi seperti Naïve Bayes, penelitian tersebut berhasil mengidentifikasi pola sentimen positif, negatif, atau netral yang memberikan gambaran persepsi konsumen terhadap Uniqlo. Informasi ini menjadi sangat penting untuk membantu perusahaan menyusun strategi pemasaran berbasis data dan meningkatkan kepuasan pelanggan. Dalam konteks penelitian ini, analisis sentimen pada platform Twitter juga bertujuan untuk memahami bagaimana keterlibatan INEOS di Manchester United memengaruhi pandangan penggemar. Dengan menggunakan model seperti RoBERTa dan VADER, analisis sentimen tidak hanya mendeteksi opini, tetapi juga mendalami konteks opini tersebut, sehingga memberikan hasil yang lebih akurat dan relevan untuk pengambilan keputusan strategis.

Penelitian [12] membandingkan performa model RoBERTa dan VADER dalam menganalisis sentimen pada data Twitter yang membahas isu perubahan iklim. VADER, sebagai model berbasis leksikon, dirancang untuk menganalisis teks pendek seperti tweet. Model ini menggunakan kamus sentimen dan aturan linguistik untuk memberikan skor polaritas sentimen (positif, netral, negatif). Keunggulan VADER terletak pada kecepatannya dalam menghasilkan analisis yang cukup akurat tanpa memerlukan pelatihan ekstensif. Hal ini menjadikannya sangat cocok untuk analisis real-time pada data publik yang dinamis. Sebaliknya, RoBERTa, yang berbasis Transformer, dirancang untuk menangkap konteks mendalam dari teks. Model ini dilatih dengan dataset besar, memungkinkan pemahaman yang lebih baik terhadap nuansa dan ambiguitas dalam teks.

Dalam penelitian tersebut, RoBERTa menunjukkan performa superior pada data yang lebih kompleks, tetapi cenderung lebih konservatif dengan mengklasifikasikan banyak data sebagai sentimen netral dibandingkan dengan VADER. Hasil penelitian menunjukkan bahwa VADER lebih efektif untuk respons cepat terhadap perubahan sentimen publik, sementara RoBERTa lebih cocok untuk analisis mendalam yang membutuhkan akurasi tinggi pada teks yang kompleks. Dalam konteks penelitian ini, kombinasi kedua model dapat memberikan hasil yang

optimal, di mana VADER dapat menangani analisis cepat untuk teks pendek, dan RoBERTa mendukung analisis mendalam pada data dengan konteks yang lebih rumit.

Dalam penelitian [13], kombinasi RoBERTa dan VADER digunakan untuk melakukan analisis sentimen pada ulasan produk. RoBERTa sebagai model berbasis Transformer, memiliki keunggulan dalam menangkap konteks yang kompleks dalam teks panjang melalui mekanisme *self-attention*. Di sisi lain, VADER adalah model berbasis leksikon yang dirancang untuk teks pendek. Model ini memberikan hasil cepat dan efisien. Penelitian tersebut menunjukkan bahwa penggabungan kedua model ini menghasilkan pendekatan analisis sentimen yang lebih komprehensif. RoBERTa digunakan untuk menangkap konteks mendalam, sedangkan VADER memberikan hasil cepat pada level kata atau frasa tertentu. Pendekatan hibrida ini memberikan wawasan yang lebih lengkap, karena masing-masing model melengkapi kelemahan yang lain. Dalam konteks penelitian ini, kombinasi RoBERTa dan VADER dapat memberikan hasil optimal dalam menganalisis sentimen keterlibatan INEOS sebagai pemilik baru Manchester United pada *platform* Twitter. RoBERTa akan fokus pada analisis mendalam terhadap opini kompleks, sementara VADER dapat memproses teks pendek dengan cepat, sehingga menghasilkan analisis yang efisien dan akurat.

Penelitian [14] memberikan wawasan tentang bagaimana berbagai faktor memengaruhi valuasi pemain sepak bola, termasuk karakteristik klub, kinerja pemain, dan popularitas. Salah satu fokus utama adalah pentingnya kepemilikan dan karakteristik klub dalam menentukan nilai pemain. Klub yang memiliki sumber daya keuangan lebih besar cenderung menawarkan transfer fee yang lebih tinggi untuk merekrut pemain berbakat. Selain itu, kehadiran pemilik baru sering kali berkontribusi pada restrukturisasi nilai klub, yang memengaruhi harga pemain yang akan direkrut atau dijual. Kepemilikan klub juga berdampak pada strategi pengelolaan aset, termasuk pemain sebagai komponen inti. Dalam konteks ini, pemain dianggap sebagai aset tidak berwujud yang dapat memberikan nilai tambah besar bagi klub, baik dalam hal kinerja di lapangan maupun dari segi nilai komersial. Studi ini juga menyoroti bahwa popularitas pemain, yang diukur melalui

aktivitas di media sosial, seperti jumlah pengikut di Instagram atau penyebutan di Google, memiliki korelasi signifikan terhadap nilai transfer mereka. Dalam penelitian ini, pendekatan serupa dapat diterapkan untuk menganalisis bagaimana keterlibatan INEOS memengaruhi sentimen yang beredar pada platform Twitter terhadap klub Manchester United. Data sentimen dari Twitter dapat digunakan untuk mengevaluasi apakah perubahan kepemilikan ini membawa dampak positif, netral, atau negatif terhadap persepsi pada platform Twitter.

Dengan mengisi kesenjangan-kesenjangan ini, penelitian ini tidak hanya memberikan kontribusi teoritis terhadap literatur analisis sentimen dan NLP, tetapi juga menawarkan wawasan praktis bagi manajemen Manchester United dan pihak-pihak yang berkepentingan untuk memahami dan mengelola opini publik secara lebih efektif.

Tabel 2. 1 Keaslian Penelitian

No	Judul Penelitian	Nama Penulis	Tahun Publikasi	Hasil Penelitian	Perbandingan Penelitian
1	Perbandingan Metode Decision Tree dan Support Vector Machine untuk Analisis Sentimen pada Instagram Mengenai Kinerja PSSI. [7]	M. Asshiddiqi dan K. Lhaksana	2020	Analisis sentimen menggunakan komentar Instagram dengan algoritma SVM menghasilkan akurasi hingga 94,36%.	Penelitian ini fokus pada analisis sentimen dari komentar Instagram terkait organisasi olahraga, sedangkan penelitian ini menggunakan Twitter untuk fokus pada keterlibatan INEOS di Manchester United.
2	Determinants of Football Players' Valuation: A Systematic Review. [14]	M. Franceschi, J. Brocard, F. Follert, dan J. Gouguet	2023	Valuasi pemain sepak bola dipengaruhi oleh kinerja, popularitas, dan karakteristik klub. Media sosial memainkan peran dalam menentukan nilai transfer pemain.	Penelitian ini mempelajari valuasi pemain, sedangkan penelitian ini berfokus pada persepsi penggemar terhadap perubahan kepemilikan klub dalam konteks keterlibatan INEOS di Manchester United.
3	Analisis Sentimen pada Ulasan Produk UNIQLO. [11]	E. Amelia dan I. Yustiana	2024	Menggunakan Naïve Bayes untuk mengidentifikasi pola sentimen positif, netral, dan negatif pada ulasan produk Uniqlo.	Penelitian ini mengaplikasikan analisis sentimen pada ulasan produk, sedangkan penelitian ini berfokus pada analisis sentimen terkait keterlibatan perusahaan dalam sepak bola melalui data Twitter.

4	Comparison of the Performance of the VADER and RoBERTa Algorithms on Twitter. [12]	D. Nurmadewi, Z. F. Jailani, dan N. K. Srimanik	2024	Perbandingan model VADER dan RoBERTa untuk analisis sentimen pada isu perubahan iklim. VADER unggul untuk teks pendek, sementara RoBERTa lebih akurat pada teks yang kompleks.	Penelitian ini membandingkan performa VADER dan RoBERTa untuk sentimen perubahan iklim, sedangkan penelitian ini menggabungkan kedua model untuk menganalisis sentimen penggemar sepak bola di Twitter.
5	Sentiment Analysis for Products Review Based on NLP Using Lexicon-Based Approach. [13]	B. Kumar, Sheetal, V. S. Badiger, dan A. Ds. Jacintha	2024	Kombinasi RoBERTa dan VADER menghasilkan analisis sentimen yang lebih komprehensif dengan menggabungkan keunggulan keduanya.	Penelitian ini fokus pada ulasan produk, sedangkan penelitian ini memanfaatkan kombinasi RoBERTa dan VADER untuk sentimen keterlibatan INEOS sebagai pemilik baru Manchester United pada platform Twitter.

2.2 Dasar Teori

Dasar teori adalah fondasi untuk memahami dan mendukung pendekatan yang digunakan dalam penelitian ini. Penelitian ini bertujuan untuk menganalisis sentimen keterlibatan INEOS sebagai pemilik baru Manchester United menggunakan model RoBERTa dan VADER. Landasan teori yang digunakan mencakup konsep dasar Natural Language Processing (NLP), analisis sentimen, pendekatan model VADER, model RoBERTa, dan model *Logistic Regression* yang akan digunakan sebagai basis untuk penggabungan model

2.3 Natural Language Processing (NLP)

Natural Language Processing (NLP) adalah cabang kecerdasan buatan yang fokus pada pemrosesan dan pemahaman bahasa manusia oleh komputer. NLP memungkinkan komputer untuk memahami, menganalisis, dan merespons teks atau ucapan manusia dalam berbagai bahasa secara alami. Menurut penelitian [15], NLP telah menjadi bagian dari kehidupan sehari-hari dalam dekade terakhir. Contoh aplikasinya meliputi:

- 1) Terjemahan Mesin Otomatis:

Teknologi seperti Google Translate membantu pengguna menerjemahkan teks antarbahasa.

- 2) Klasifikasi Teks:

Memfilter email spam sehingga hanya pesan penting yang masuk ke kotak masuk.

- 3) Pencarian Informasi:

Mesin pencari menggunakan algoritma NLP untuk memberikan hasil pencarian yang lebih relevan dengan memahami maksud pengguna.

- 4) Sistem Dialog:

Chatbot dan asisten virtual seperti Siri dan Alexa yang memberikan respons cerdas berdasarkan permintaan pengguna.

Aplikasi-aplikasi ini bergantung pada serangkaian ide utama, termasuk algoritma, linguistik, logika, dan statistik. Dalam konteks akademis, NLP terintegrasi dengan berbagai disiplin ilmu untuk menciptakan solusi yang efektif bagi permasalahan berbasis teks. Tema utama dalam NLP modern melibatkan

pemahaman semantik, sintaksis, dan konteks untuk mendukung teknologi seperti analisis sentimen, pengenalan entitas, dan penerjemahan.

2.3.1 Jenis-Jenis Natural Language Processing (NLP)

Natural Language Processing (NLP) mencakup berbagai teknik dan aplikasi yang dirancang untuk memungkinkan komputer memahami, menganalisis, dan menghasilkan bahasa manusia. Menurut Manglik, jenis-jenis utama NLP dapat diklasifikasikan berdasarkan tujuan dan teknik yang digunakan, meliputi:

1) Text Classification

Text classification adalah proses mengelompokkan teks ke dalam kategori tertentu. Contoh aplikasi termasuk analisis sentimen, deteksi spam, dan klasifikasi dokumen. Model berbasis machine learning, seperti Naïve Bayes dan Support Vector Machines (SVM), sering digunakan untuk tugas ini. Pada NLP modern, model berbasis deep learning, seperti RoBERTa, juga digunakan untuk meningkatkan akurasi pada tugas klasifikasi teks.

2) Information Retrieval and Extraction

Teknik ini digunakan untuk menemukan informasi relevan dari kumpulan data besar. Proses ini sering mencakup dua tahap utama:

- a) Information Retrieval: Mencari dan mengambil dokumen yang relevan berdasarkan permintaan pengguna.
- b) Information Extraction: Mengidentifikasi fakta atau entitas penting dalam teks, seperti nama, tempat, dan waktu. Named Entity Recognition (NER) adalah salah satu contoh populer dari teknik ini.

3) Sentiment Analysis

Analisis sentimen bertujuan untuk mengidentifikasi opini atau emosi dalam teks. Teknik ini digunakan untuk mengetahui apakah sentimen pengguna terhadap suatu topik positif, negatif, atau netral. Contoh aplikasinya meliputi ulasan produk, opini di media sosial, dan survei pelanggan. VADER adalah salah satu alat berbasis leksikon yang sering digunakan untuk tugas ini, sementara Transformer seperti BERT dan RoBERTa unggul dalam memahami konteks sentimen yang kompleks.

4) Language Modeling

Language modeling bertujuan untuk mempelajari distribusi kata dalam sebuah bahasa untuk memprediksi kemungkinan kata berikutnya dalam suatu teks. Teknik ini menjadi dasar dalam berbagai aplikasi, seperti *autocomplete* pada ponsel atau terjemahan mesin. Model berbasis Transformer, seperti BERT, GPT, dan RoBERTa, telah membawa kemajuan signifikan dalam tugas ini.

5) *Machine Translation*

Teknik ini digunakan untuk menerjemahkan teks dari satu bahasa ke bahasa lain. Contoh populer adalah Google Translate dan DeepL Translator. Pendekatan modern menggunakan model sequence-to-sequence berbasis Transformer untuk meningkatkan kualitas terjemahan.

6) *Speech-to-Text and Text-to-Speech*

Seiring dengan berkembangnya teknologi interaksi manusia dan mesin, kemampuan sistem komputer untuk memahami dan menghasilkan ucapan menjadi semakin penting. Dua teknologi utama yang berperan dalam bidang ini adalah *Speech-to-Text (STT)* dan *Text-to-Speech (TTS)*. Keduanya merupakan bagian dari Natural Language Processing (NLP) yang berfokus pada pemrosesan input dan output dalam bentuk suara. Penjelasan SST dan TTS ialah sebagai berikut:

- a) *Speech-to-Text (STT)*: memungkinkan sistem untuk mengenali ucapan manusia dan mengubahnya menjadi teks tertulis secara otomatis. Teknologi ini umum digunakan dalam aplikasi seperti asisten virtual, transkripsi otomatis, dan sistem pencarian berbasis suara.
- b) *Text-to-Speech (TTS)*: Sebaliknya dari STT, TTS bekerja dengan cara mengubah teks tertulis menjadi suara yang dapat didengar oleh manusia. Fungsionalitas ini banyak dimanfaatkan dalam perangkat lunak pembaca teks, layanan aksesibilitas bagi penyandang disabilitas, serta dalam pengembangan chatbot yang bersuara.

7) *Question Answering*

Teknik ini memungkinkan sistem menjawab pertanyaan pengguna berdasarkan data teks yang diberikan. Model seperti RoBERTa dan BERT

sering digunakan dalam sistem pencarian berbasis konteks atau chatbot cerdas

2.3.2 Faktor-Faktor Yang Mempengaruhi NLP

Natural Language Processing (NLP) adalah bidang yang melibatkan interaksi kompleks antara komputer dan bahasa manusia. Keberhasilan implementasi NLP dipengaruhi oleh berbagai faktor teknis dan non-teknis, yang secara langsung memengaruhi kualitas hasil analisis dan performa model. Menurut Manglik, beberapa faktor utama yang memengaruhi NLP meliputi:

1) Kualitas Data

Data merupakan komponen inti dalam NLP. Kualitas data, baik dari segi keakuratan maupun relevansinya, sangat memengaruhi performa model. Data yang tidak bersih, seperti teks yang penuh dengan kesalahan ketik, simbol tidak relevan, atau noise, dapat mengurangi efisiensi algoritma. Oleh karena itu, preprocessing data, termasuk tokenisasi, penghapusan stopwords, dan normalisasi teks, menjadi langkah penting dalam memastikan data yang digunakan optimal.

2) Ukuran Dataset

Ukuran dataset juga menjadi faktor kunci. Model deep learning seperti Transformer memerlukan dataset besar untuk menangkap pola dan konteks bahasa yang kompleks. Dataset kecil dapat menyebabkan overfitting, di mana model belajar terlalu detail dari data pelatihan sehingga tidak dapat bekerja dengan baik pada data baru.

3) Pemilihan Model

Pemilihan model algoritma sangat memengaruhi hasil dari tugas NLP. Model berbasis leksikon seperti VADER efektif untuk analisis teks pendek, sedangkan model berbasis deep learning seperti RoBERTa unggul dalam memahami konteks mendalam dalam teks panjang. Pemilihan model harus disesuaikan dengan jenis tugas dan karakteristik data.

4) Bahasa dan Kompleksitas Linguistik

NLP untuk bahasa tertentu seperti bahasa Inggris lebih maju karena memiliki lebih banyak sumber daya, seperti dataset dan model prapelatihan. Sebaliknya, bahasa dengan morfologi yang kompleks atau

sumber daya terbatas menghadirkan tantangan unik dalam implementasi NLP.

5) Kapasitas Komputasi

Model modern seperti Transformer membutuhkan kapasitas komputasi yang besar, termasuk GPU atau TPU untuk melatih dan menjalankan model secara efisien. Keterbatasan perangkat keras dapat memengaruhi waktu pelatihan, efisiensi, dan kemampuan model dalam menangani data besar.

6) Hyperparameter Tuning

Parameter seperti *learning rate*, jumlah lapisan, dan ukuran batch memainkan peran penting dalam meningkatkan kinerja model NLP. Hyperparameter yang tidak dioptimalkan dapat menyebabkan model gagal belajar dengan benar atau memerlukan waktu pelatihan lebih lama.

7) Konteks dan Domain Spesifik

Model NLP harus disesuaikan dengan konteks atau domain spesifik. Contohnya, model yang digunakan untuk analisis sentimen di media sosial harus mampu menangani slang, emoji, dan frasa informal yang umum ditemukan di platform seperti Twitter.

2.4 Analisis Sentimen

Analisis sentimen adalah proses untuk memahami, mengekstraksi, dan mengklasifikasikan emosi atau opini dalam teks menjadi kategori positif, negatif, atau netral. Menurut jurnal [16], analisis sentimen menjadi semakin penting seiring dengan meningkatnya jumlah data teks yang dihasilkan di era digital. Analisis ini digunakan di berbagai domain, seperti evaluasi ulasan produk, opini publik terhadap suatu isu, dan analisis media sosial. Dalam penelitian ini, analisis sentimen diterapkan untuk mengevaluasi sentimen penggemar terhadap keterlibatan INEOS di Manchester United menggunakan data dari Twitter.

Pendekatan analisis sentimen dapat dibagi menjadi dua kategori utama, yaitu pendekatan berbasis leksikon (*lexicon-based approach*) dan pendekatan berbasis pembelajaran mesin (*machine learning approach*). Kedua pendekatan ini memiliki metode dan keunggulan masing-masing dalam menangani tugas klasifikasi sentimen.

2.5 Lexicon-Based Approach

Pendekatan berbasis leksikon bergantung pada kamus atau daftar kata yang telah ditentukan sebelumnya, yang masing-masing kata diberi nilai polaritas tertentu, seperti positif, negatif, atau netral. Metode ini bekerja dengan menghitung skor polaritas berdasarkan kata-kata yang ditemukan dalam teks. Sebagai contoh, model VADER (*Valence Aware Dictionary and sEntiment Reasoner*) adalah salah satu model berbasis leksikon yang dirancang khusus untuk teks pendek, seperti tweet. VADER mempertimbangkan intensitas emosi dari kata-kata, termasuk efek dari negasi (*not*), intensifier (*very*), atau emotikon.

Pendekatan ini unggul dalam hal kecepatan dan efisiensi, terutama untuk data dengan jumlah besar dan format sederhana. Namun, kelemahannya adalah ketergantungan pada kelengkapan leksikon, sehingga sulit untuk menangani konteks kompleks atau kata-kata baru yang tidak ada dalam kamus. Dalam penelitian ini, VADER digunakan untuk menganalisis sentimen tweet pendek yang berkaitan dengan Manchester United, karena pendekatan ini efektif untuk analisis cepat.

2.6 Machine Learning Approach

Pendekatan berbasis pembelajaran mesin menggunakan model yang dilatih pada dataset berlabel untuk mempelajari pola sentimen dalam teks. Model seperti Naïve Bayes, Support Vector Machines (SVM), dan model berbasis Transformer seperti BERT atau RoBERTa merupakan contoh populer dalam pendekatan ini. Dalam proses pelatihannya, fitur-fitur teks, seperti frekuensi kata (TF-IDF) atau representasi *word embeddings*, diekstraksi untuk melatih model dalam mengenali sentimen.

Keunggulan dari pendekatan ini adalah kemampuannya untuk menangkap konteks dan hubungan antar kata secara lebih baik, terutama dengan model berbasis deep learning. RoBERTa, misalnya, unggul dalam memahami konteks yang kompleks dalam teks panjang melalui mekanisme *self-attention*. Pendekatan ini juga fleksibel terhadap variasi data, termasuk kata-kata baru atau slang yang sering ditemukan di media sosial.

Namun, pendekatan pembelajaran mesin memiliki tantangan, seperti kebutuhan akan dataset besar untuk pelatihan dan kapasitas komputasi yang tinggi.

Dalam penelitian ini, RoBERTa digunakan untuk menganalisis tweet dengan konteks yang lebih kompleks, sehingga memberikan hasil yang lebih akurat dibandingkan pendekatan berbasis leksikon.

2.7 VADER & Lexicon-Based Approach Model

VADER (*Valence Aware Dictionary and sEntiment Reasoner*) adalah salah satu model analisis sentimen yang menggunakan pendekatan berbasis leksikon, yang dirancang untuk menganalisis teks pendek seperti tweet dan komentar di media sosial. Model ini memanfaatkan kamus kata yang telah diberi nilai sentimen berdasarkan polaritasnya, yang bisa berupa positif, negatif, atau netral. VADER sangat populer dalam analisis media sosial karena kemampuannya untuk menangani ekspresi yang lebih kasual, seperti emotikon, slang, dan singkatan. Menurut [17], pendekatan berbasis leksikon seperti VADER mengidentifikasi dan mengklasifikasikan sentimen dengan memeriksa kata-kata yang ada dalam teks dan memberi mereka skor polaritas berdasarkan kamus yang telah ditentukan.

Pada prinsipnya, pendekatan berbasis leksikon melibatkan dua elemen utama: kamus sentimen dan aturan linguistik. Kamus sentimen berisi kata-kata yang telah diberikan skor, yang mengindikasikan seberapa positif atau negatif kata tersebut. Aturan linguistik digunakan untuk menangani perubahan intensitas sentimen yang bisa terjadi dengan adanya kata-kata pengubah, seperti penguat (*very, extremely*) atau penegas (*not, never*).

Dalam model VADER, skor sentimen dihitung dengan mengkombinasikan dua komponen yaitu, komponen dasar yang dihitung dari kata-kata dalam teks, dan komponen pengubah yang menyesuaikan skor berdasarkan konteks penggunaan kata. Proses ini memungkinkan model untuk menghasilkan tiga kategori sentimen utama yaitu, Positif, Negatif, dan Netral.

Untuk menghitung skor sentimen, VADER menggunakan rumus yang menggabungkan nilai polaritas kata dan pengaruh pengubah. Rumus dasar untuk skor sentimen dapat dijelaskan sebagai berikut:

$$Sentiment\ Score = \sum_{i=1}^n score_i \times weight_i$$

keterangan:

$score_i$: skor polaritas untuk kata i dalam teks.

$weight_i$:pengaruh intensitas yang dimodifikasi oleh pengubah linguistik, seperti kata penguat atau penegatif.

Untuk masing-masing kata dalam teks, VADER memberikan skor antara -1 (sangat negatif) hingga +1 (sangat positif), dengan 0 menunjukkan netral. Selain itu, untuk memperhitungkan kontekstualisasi, VADER akan menyesuaikan skor berdasarkan elemen pengubah dalam kalimat, misalnya:

- 1) "extremely happy" (lebih positif)
- 2) "not happy" (negatif)

2.7.1 Kelebihan dan Kekurangan VADER

VADER unggul dalam menangani teks pendek yang informal, seperti tweet atau komentar media sosial. Model ini mudah digunakan karena tidak memerlukan proses pelatihan, menjadikannya cocok untuk analisis cepat. Namun, pendekatan berbasis leksikon, termasuk VADER, memiliki kelemahan dalam memahami konteks yang lebih kompleks. Kata-kata dengan makna ambigu atau ironi sering kali disalahartikan.


Sebagai contoh:

- 1) Kalimat "Not bad at all" dapat menghasilkan sentimen negatif jika tidak memperhatikan negasi dan konteks.
- 2) Kata "bad" dalam contoh ini sebenarnya memiliki konotasi positif karena adanya elemen negasi "not".

Untuk meningkatkan hasil analisis, preprocessing yang baik diperlukan, seperti normalisasi teks dan penghilangan noise.

2.8 RoBERTa & Machine Learning Approach Model

RoBERTa (*Robustly Optimized BERT Approach*) adalah model berbasis Transformer yang dikembangkan untuk meningkatkan performa analisis teks dibandingkan model BERT (Bidirectional Encoder Representations from Transformers) [18]. Model ini mempertahankan komponen utama Transformer yaitu mekanisme *multi-headed self-attention*, namun dengan beberapa penyempurnaan dalam hal pelatihan. *Self-attention* merupakan komponen fundamental dalam arsitektur Transformer yang pertama kali diperkenalkan oleh [19].



Gambar 2. 1 Arsitektur transformers

RoBERTa menggunakan pendekatan *self-attention*, yang memungkinkan model untuk fokus pada hubungan antar kata dalam kalimat. Mekanisme ini memungkinkan model untuk memproses seluruh rangkaian input secara paralel dengan menghitung representasi berbobot dari setiap posisi dalam sequence berdasarkan hubungannya dengan semua posisi lainnya. Ini mengatasi kelemahan model sekuensial seperti RNN yang sulit menangkap konteks global dalam teks panjang. Pendekatan machine learning menggunakan RoBERTa melibatkan pelatihan model pada dataset besar untuk menghasilkan representasi kontekstual. Model ini bekerja dengan memahami hubungan dua arah dalam teks, membuatnya sangat efektif untuk tugas-tugas analisis sentimen yang memerlukan pemahaman mendalam.

Pendekatan machine learning pada analisis sentimen bertujuan untuk melatih model dalam mengenali pola sentimen berdasarkan dataset berlabel. Dalam hal ini, model seperti RoBERTa bekerja dengan representasi teks yang dihasilkan dari preprocessing, seperti tokenisasi dan pembuatan embedding kata. Fitur-fitur ini dimasukkan ke dalam model untuk klasifikasi sentimen. Proses ini melibatkan beberapa langkah utama:

1. Preprocessing Data: Membersihkan teks, seperti menghapus noise dan melakukan tokenisasi.

2. Feature Extraction: Mengubah teks menjadi representasi numerik dengan metode seperti TF-IDF atau embedding berbasis Transformer.
3. Model Training: Melatih model dengan data latih yang telah diberi label sentimen (positif, negatif, netral).
4. Prediction: Menerapkan model pada data uji untuk memprediksi sentimen.

RoBERTa dirancang untuk menangani kompleksitas teks, seperti idiom dan konteks mendalam, yang sulit dipahami oleh model leksikon sederhana seperti VADER.

2.8.1 Penghitungan Sentiment Score dengan Model RoBERTa

Model RoBERTa tidak menghitung *sentiment score* secara langsung seperti model berbasis leksikon seperti VADER. Sebagai gantinya, RoBERTa menghasilkan representasi numerik (embedding) dari teks input dan mengklasifikasikannya berdasarkan probabilitas sentimen yang dihasilkan oleh lapisan akhir model. Berikut adalah langkah-langkah penghitungan *sentiment score* menggunakan RoBERTa:

1) Tokenisasi dengan BPE (*Byte Pair Encoding*)

Berbeda dengan model berbasis lexicon yang melakukan tokenisasi pada tingkat kata, model RoBERTa menggunakan Byte Pair Encoding untuk memecah kata menjadi dalam bentuk sub-kata atau dengan kata lain tokenisasi yang dilakukan pada tingkat sub-kata. Kemudian sub-kata diubah menjadi indeks numerik yang sesuai dengan kamus model prelatih

2) Pemrosesan melalui Transformer

Setelah tokenisasi, indeks numerik diproses melalui lapisan Transformer RoBERTa. Setiap token diberi representasi embedding yang mencakup hubungan antar token. Representasi ini dihasilkan oleh mekanisme *self-attention* [20]:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Keterangan:

Q, K, V : Matriks Query, Key, dan Value token

d_k : Dimensi Key

Hasilnya adalah embedding untuk setiap token, yang menangkap konteks dari seluruh teks.

3) Lapisan akhir untuk klasifikasi

Hasil dari Transformer diteruskan ke lapisan klasifikasi (*fully connected layer*), yang memetakan embedding menjadi skor probabilitas untuk setiap kelas sentimen (positif, negatif, netral).

Fungsi softmax digunakan untuk mengubah output mentah (logit) dari model menjadi probabilitas yang dapat diinterpretasikan. Probabilitas ini menunjukkan seberapa besar kemungkinan input x termasuk dalam kelas k .

$$P(y = k|x) = \frac{\exp(z_k)}{\sum_i \exp(z_i)}$$

Keterangan:

z_k : Logit untuk kelas k (positif, negatif, netral).

$P(y = k|x)$: Probabilitas sentimen k berdasarkan input x

4) Penentuan Sentimen

Sentimen ditentukan berdasarkan probabilitas kelas tertinggi. Sebagai contoh:

- a) Probabilitas yang dihasilkan: Positif (0.75), Negatif (0.15), Netral (0.10).
- b) Sentimen: Positif, karena memiliki probabilitas tertinggi (0.75).

RoBERTa, sebagai model berbasis Transformer, telah menunjukkan kinerja yang baik dalam berbagai tugas Natural Language Processing (NLP), termasuk analisis sentimen. Kemampuannya untuk memahami hubungan kontekstual antar kata dalam sebuah kalimat menjadikannya lebih efektif dalam menangani teks dengan struktur kompleks, seperti yang sering ditemukan dalam unggahan media sosial. Dengan pendekatan pembelajaran mendalam dan representasi teks yang dikembangkan melalui proses pretraining pada skala data yang besar, RoBERTa mampu menghasilkan klasifikasi sentimen yang lebih akurat dibandingkan metode berbasis leksikon. Oleh karena itu, dalam penelitian ini, RoBERTa digunakan sebagai salah satu model utama untuk mengevaluasi sentimen penggemar terhadap keterlibatan INEOS dalam kepemilikan Manchester United.

2.9 Logistic Regression sebagai Meta-Classifier pada Ensemble Stacking

Ensemble stacking merupakan salah satu pendekatan dalam *ensemble learning* yang mengombinasikan beberapa model pembelajaran dasar (*base learners*) untuk menghasilkan prediksi akhir yang lebih akurat. Pada metode ini, hasil prediksi dari *base learners* tidak langsung dijadikan keputusan akhir, melainkan dijadikan input tambahan bagi sebuah model tingkat kedua yang disebut *meta-classifier*. Model ini berfungsi untuk mempelajari pola kesalahan dan keunggulan dari setiap *base learner*, sehingga dapat melakukan penggabungan prediksi dengan lebih optimal.

Dibahas pada [21] yang menggunakan Logistic Regression sebagai *meta-classifier*, model Logistic Regression dipilih karena sifatnya yang sederhana, efisien, dan memiliki interpretabilitas yang baik dalam memetakan probabilitas ke dalam dua atau lebih kelas. Algoritma ini bekerja dengan membangun fungsi logistik (*sigmoid function*) yang menghubungkan antara variabel input (hasil prediksi dari *base learners*) dengan probabilitas kelas target. Dengan demikian, Logistic Regression mampu menentukan bobot optimal bagi setiap *base learner* berdasarkan kontribusinya terhadap akurasi prediksi akhir. Secara matematis, Logistic Regression dalam konteks meta-classifier dapat diformulasikan sebagai berikut:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}$$

Keterangan:

$P(y = 1|x)$: Probabilitas bahwa variabel dependen Y akan bernilai 1

e : Basis normal logit bernilai sekitar sekitar 2.71828.

β_0 : Konstanta atau intercept dalam model.

$x_1, x_2, \dots, x_n$: prediksi yang dihasilkan oleh *base learners*.

Dalam penelitian terkait, penggunaan Logistic Regression sebagai meta-classifier terbukti mampu meningkatkan kinerja dibandingkan dengan *base learner* yang berdiri sendiri. menunjukkan bahwa stacking dengan Logistic Regression sebagai *meta-classifier* dapat meningkatkan akurasi hingga 0,71% dibandingkan model terbaik pada level *base learner*.

Dengan demikian, bab ini telah menguraikan teori-teori dasar yang menjadi pijakan dalam penelitian ini, dimulai dari pemahaman mengenai Natural Language Processing (NLP) dan berbagai aplikasinya, termasuk analisis sentimen sebagai fokus utama. Dua pendekatan utama dalam analisis sentimen, yakni lexicon-based dan machine learning-based, telah dibahas secara mendalam melalui pemaparan model VADER dan RoBERTa. Selain itu, penjelasan tentang perhitungan skor sentimen serta arsitektur dan mekanisme kerja dari model Transformer telah diuraikan guna memberi pemahaman yang komprehensif terhadap metode yang digunakan.

Dengan pemahaman ini, pembaca diharapkan memperoleh gambaran yang jelas mengenai dasar teoritis dari teknik-teknik yang digunakan dalam penelitian, khususnya dalam konteks analisis sentimen pada data media sosial. Seluruh teori yang telah dipaparkan akan digunakan sebagai fondasi dalam perancangan metode penelitian yang akan dijelaskan lebih lanjut pada Bab III.

BAB III METODE PENELITIAN

3.1 Objek Penelitian

Objek penelitian ini adalah sentimen yang tersebar pada platform terhadap keterlibatan INEOS sebagai pemilik baru klub Manchester United. Sentimen ini diambil dari platform media sosial Twitter dalam bentuk teks pendek (tweet). Data yang digunakan terdiri dari opini publik yang relevan dengan kata kunci spesifik seperti "Manchester United," "INEOS," dan istilah terkait lainnya.

Penelitian ini memanfaatkan data tweet yang dikumpulkan selama periode tertentu, yaitu antara 23 Desember 2023 hingga 25 Desember 2024. Data ini mencakup tweet berbahasa Inggris untuk memastikan konsistensi dalam analisis menggunakan teknik Natural Language Processing (NLP). Pemilihan data dari Twitter didasarkan pada karakteristiknya sebagai platform yang memungkinkan pengguna untuk menyampaikan opini dan emosi dalam bentuk teks, yang sangat cocok untuk dianalisis menggunakan model seperti VADER dan RoBERTa.


Pendekatan penelitian yang digunakan dalam penelitian ini adalah pendekatan kuantitatif dengan analisis data sekunder. Data tweet yang telah dikumpulkan dianalisis menggunakan teknik analisis sentimen untuk mengidentifikasi sentimen positif, negatif, dan netral. Dua model utama, yaitu VADER dan RoBERTa, digunakan untuk mengevaluasi sentimen berdasarkan konteks dan intensitas emosi dalam teks.

Penelitian ini juga membatasi fokus pada sentimen yang berkaitan dengan perubahan kepemilikan klub sepak bola, tanpa melibatkan faktor eksternal lain seperti taktik permainan atau kinerja keuangan klub. Dengan batasan ini, penelitian bertujuan untuk mengeksplorasi dampak keterlibatan INEOS terhadap persepsi dan emosi penggemar secara lebih mendalam.

3.2 Alur Penelitian

Alur penelitian ini dirancang untuk mengevaluasi sentimen keterlibatan INEOS sebagai pemilik baru Manchester United, menggunakan pendekatan analisis sentimen berbasis Natural Language Processing (NLP). Tahapan penelitian

terdiri dari beberapa langkah yang sistematis, sebagaimana digambarkan pada Gambar 3.1 Setiap tahapan yang terdapat pada alur disertai dengan uraian penjelasan.



Gambar 3. 1 Alur Penelitian

3.2.1 Pengumpulan Data

Penelitian ini menggunakan dua jenis data yang memiliki fungsi berbeda, yaitu untuk membandingkan performa model dan untuk menganalisis sentimen

terhadap keterlibatan INEOS sebagai pemilik baru klub Manchester United. Penjelasan kedua data tersebut sebagai berikut:

1) Data untuk perbandingan model

Agar model analisis sentimen dapat dievaluasi secara objektif, diperlukan dataset yang telah memiliki label sentimen. Dataset ini digunakan untuk menguji seberapa baik model dalam mengklasifikasikan sentimen ke dalam kategori negatif, netral, atau positif. Dalam penelitian ini digunakan dataset berlabel yang diambil dari platform HuggingFace, yakni dataset *TweetEval* yang dikembangkan oleh CardiffNLP. Dataset ini dipilih karena bersifat terbuka (*open-access*) dan telah banyak digunakan dalam berbagai penelitian serupa [22]. Dataset ini digunakan untuk proses pelatihan dan evaluasi model sebelum diterapkan pada data aktual.

2) Data sentimen publik

Untuk menganalisis opini publik terhadap keterlibatan INEOS sebagai pemilik baru Manchester United, data dikumpulkan langsung dari media sosial Twitter. Proses pengambilan data dilakukan secara otomatis menggunakan teknik *web scraping*, dengan bantuan alat dari repository *Tweet-Harvest*. Data yang digunakan dalam penelitian ini diambil pada rentang waktu 23 Desember 2023 hingga 25 Desember 2024.

Tweet-Harvest adalah sebuah proyek sumber terbuka (*open-source*) yang tersedia di GitHub, yang memungkinkan pengguna untuk mengakses dan mengunduh tweet melalui Twitter API. Data hasil scraping ini tidak memiliki label sentimen dan digunakan sebagai bahan utama untuk dianalisis dengan model yang telah dilatih sebelumnya.

3.2.2 Preprocessing, Splitting and Balancing Data

Dalam analisis sentimen teknik preprocessing sudah seringkali digunakan yang bertujuan untuk mempersiapkan data teks yang nantinya akan diklasifikasikan. Setelah data dikumpulkan kemudian diproses teknik preprocessing digunakan untuk menormalkan teks. Seperti yang dijelaskan [23] tahap-tahap preprocessing mencakup tokenisasi, penghapusan simbol yang tidak relevan, menormalisasi teks, serta memfilter dan menyimpan informasi yang berguna. Dalam penelitian ini dataset berlabel *tweet_eval/sentiment* dari

HuggingFace sudah relatif bersih. Oleh karena itu, preprocessing dapat dilakukan secara minimal dengan memanfaatkan tokenizer bawaan dari model RoBERTa, yaitu *RobertaTokenizerFast*. Tokenizer ini secara otomatis melakukan tokenisasi, *padding* dan *truncation* untuk keseragaman panjang teks, dan mengkonversi teks menjadi bentuk token yang dapat diproses oleh model.

Setelah tahap pra-pemrosesan, data dibagi menjadi tiga subset: data latih, data validasi, dan data uji. Proses ini dilakukan secara bertahap untuk memastikan bahwa model memiliki data pelatihan yang cukup, sekaligus dapat diuji secara objektif. Tahap pertama dilakukan dengan membagi data awal menjadi 80% untuk pelatihan dan 20% untuk pengujian. Selanjutnya, 10% dari data latih digunakan sebagai data validasi, sehingga proporsi akhirnya adalah 72% untuk pelatihan, 8% untuk validasi, dan 20% untuk pengujian. Pembagian ini mengikuti praktik umum dalam penelitian analisis sentimen berbasis transformer seperti RoBERTa maupun model hybrid [24]. Untuk menjaga konsistensi distribusi label sentimen pada masing-masing subset, digunakan metode stratified sampling. Teknik ini mempertahankan proporsi kelas (negatif, netral, dan positif) dalam setiap subset data, sehingga menghindari bias terhadap kelas mayoritas. Penggunaan metode ini juga umum diterapkan dalam penelitian terkini yang menangani klasifikasi teks dengan data tidak seimbang [25]. Dengan demikian, pembagian data secara berstrata memungkinkan proses pelatihan dan pengujian model dilakukan secara adil, serta meningkatkan kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Tabel 3. 1 Perbandingan data training awal dan setelah pembagian

Jenis Data	Positif	Netral	Negatif	Total
Data awal	17.849	20.673	7093	45.615
Data Latih	14.885	12.851	5.106	32.842
Data Uji	4.134	3.570	1.419	9.123
Data Validasi	1.654	1.428	568	3.650

Data latih (training set) yang telah dibagi sebesar 72% dari total dataset kemudian diseimbangkan menggunakan dua pendekatan konvensional, yaitu *Random Oversampling* (ROS) dan *Random Undersampling* (RUS). ROS

merupakan teknik penyeimbangan dengan cara menggandakan sampel dari kelas minoritas, sedangkan RUS dilakukan dengan mengurangi jumlah sampel dari kelas mayoritas [26]. Penyeimbangan ini diterapkan hanya pada data latih setelah proses stratified splitting untuk menghindari *data leakage*. Kedua metode ini dipilih karena terbukti efektif dalam meningkatkan performa model pada kelas minoritas [27].

Tabel 3. 2 Pembagian data balancing

Jenis Data	Positif	Netral	Negatif	Total
Data Latih Awal	14.885	12.851	5.106	32.842
Oversampling Data	14.885	14.885	14.885	44.655
Undersampling Data	5.106	5.106	5.106	15.318

3.2.3 Model Preparation

Tahap ini bertujuan untuk mempersiapkan model yang akan digunakan dalam proses pelatihan dan evaluasi analisis sentimen. Dua jenis pendekatan model yang digunakan dalam penelitian ini adalah RoBERTa, sebuah model transformer berbasis pre-trained language model, dan VADER, sebuah pendekatan berbasis leksikon (lexicon-based) yang dirancang untuk menganalisis sentimen pada teks pendek seperti cuitan Twitter. Tahap ini juga melibatkan pengaturan parameter pelatihan seperti learning rate, batch size, dan jumlah epochs untuk RoBERTa. Semua model disiapkan dalam lingkungan pipeline yang terintegrasi agar siap diuji dalam tahapan selanjutnya, yaitu fine-tuning RoBERTa dan threshold optimization pada VADER. Berikut adalah persiapan pada setiap model:

3.2.3.1 Persiapan model RoBERTa

Pada penelitian ini, digunakan model roberta-base dari pustaka *Hugging Face Transformers*, yang telah dilatih pada dataset berskala besar dan akan dilakukan *fine-tuning* terhadap data tweet berlabel dari dataset *TweetEval/Sentiment*. Sebelum memasuki tahap pelatihan, dilakukan proses tokenisasi menggunakan *RobertaTokenizerFast* untuk mengonversi teks menjadi format token yang dapat dipahami oleh model.

Setelah data melalui tahap tokenisasi berhasil dipersiapkan, tahap selanjutnya adalah menentukan parameter pelatihan. Dalam penelitian ini, fine-tuning terhadap model dilakukan dengan menggunakan pustaka *Trainer* dari

Hugging Face, yang memungkinkan pengaturan parameter pelatihan secara sistematis. Beberapa parameter penting yang digunakan antara lain:

1) Batch size: 16

Strategi ini digunakan untuk mengakomodasi keterbatasan memori GPU, namun tetap menjaga jumlah data yang diproses per iterasi cukup besar untuk stabilitas pelatihan.

2) Epochs: 2

Jumlah ini dipilih berdasarkan praktik umum fine-tuning pada model prelatih, yang menunjukkan performa optimal dengan jumlah epoch rendah, guna mencegah *overfitting*.

3) Weight Decay: 0.01

Jumlah tersebut dipilih untuk membantu mencegah *overfitting* dengan memberikan regularisasi pada bobot model.

4) Strategi Evaluasi & Penyimpanan model: epoch

Model dievaluasi setiap akhir *epoch* menggunakan metrik *F1-score*. Hal ini bertujuan untuk memastikan bahwa model terbaik yang dimuat adalah berdasarkan nilai *F1-score* tertinggi. kemudian, model disimpan setiap *epoch* selama pelatihan. Strategi evaluasi ini membantu memantau performa model secara berkala selama proses pelatihan.

3.2.3.2 Persiapan model VADER

Sementara itu, VADER dipersiapkan dengan menginisialisasi leksikon sentimen dan akan digunakan untuk memberikan penilaian sentimen berbasis skor komposit dari teks. Meskipun tidak memerlukan proses pelatihan, VADER tetap diuji dan dioptimalkan pada dataset yang sama guna memperoleh ambang batas (threshold) yang optimal untuk klasifikasi.

3.2.4 Fine-tuning RoBERTa model

Setelah melalui tahap *preprocessing* dan pembagian data, penelitian ini melakukan *fine-tuning* pada model RoBERTa. RoBERTa merupakan salah satu arsitektur transformer yang telah melalui pelatihan awal (*pretraining*) pada korpus besar, dan terbukti unggul dalam berbagai tugas *Natural Language Processing*, termasuk analisis sentimen.

Dalam konteks penelitian ini, model roberta-base digunakan dan disesuaikan (fine-tuned) menggunakan dataset TweetEval yang telah diubah kedalam 3 bentuk dataframe (tanpa *balancing*, *oversampling*, *undersampling*) untuk mencari performa akurasi dan f1-score model terbaik dari ketiga dataframe. Proses fine-tuning dilakukan agar model lebih memahami konteks domain data Twitter. Hal ini didukung oleh penelitian [28] yang menunjukkan bahwa proses *fine-tuning* RoBERTa pada data spesifik mampu meningkatkan performa klasifikasi sentimen secara signifikan, dibandingkan hanya menggunakan model pre-trained secara langsung. Fine-tuning memungkinkan adaptasi model terhadap karakteristik linguistik pada data pelatihan, termasuk gaya bahasa informal, singkatan, dan ekspresi khas media sosial. Dengan demikian, model menjadi lebih akurat dalam mengklasifikasikan teks ke dalam kelas negatif, netral, atau positif, sebagaimana dibutuhkan dalam analisis ini.

3.2.5 Optimizing VADER threshold

Dalam penelitian ini, model VADER (Valence Aware Dictionary and sEntiment Reasoner) digunakan sebagai baseline untuk melakukan analisis sentimen berbasis leksikon. Secara default, VADER mengklasifikasikan sentimen berdasarkan skor *compound*. jika skor *compound* ≤ -0.05 dianggap negatif, sebagai positif jika ≥ 0.05 , dan jika skor terletak diantara -0.05 dan 0.05 sebagai netral. Namun, ambang batas ini bersifat umum atau *default* dan tidak selalu optimal untuk semua jenis data.

Agar klasifikasi lebih sesuai dengan karakteristik dataset yang digunakan dalam penelitian ini, ambang batas (*threshold*) tersebut disesuaikan melalui pendekatan evaluasi performa. Proses optimasi dilakukan dengan cara mencoba berbagai pasangan nilai ambang batas dari 0.01 hingga 0.5. Untuk setiap pasangan *threshold*, dilakukan prediksi terhadap data uji, kemudian dihitung skor F1 dengan rata-rata berbobot (*weighted*). Ambang batas yang menghasilkan nilai F1-score tertinggi kemudian dipilih sebagai *threshold* optimal. Berikut ini adalah potongan kode yang digunakan:

```

def vader_predict(texts, th_pos=0.05, th_neg=-0.05):
    preds = []
    for text in texts:
        score = analyzer.polarity_scores(text)["compound"]
        if score >= th_pos:
            preds.append(2) # positive
        elif score <= th_neg:
            preds.append(0) # negative
        else:
            preds.append(1) # neutral
    return preds

best_f1 = 0
best_threshold = (0.05, -0.05)

# Uji threshold dari 0.01 hingga 0.5
thresholds = np.arange(0.01, 0.5, 0.01)

for th in thresholds:
    preds = vader_predict(test_df["text"], th_pos=th, th_neg=-th)
    f1 = f1_score(test_df["label"], preds, average="weighted")

    if f1 > best_f1:
        best_f1 = f1
        best_threshold = (th, -th)

print("✅ Best F1-score:", best_f1)
print("✅ Best thresholds (pos, neg):", best_threshold)

```

✓ 43.1s

Gambar 3. 2 Potongan kode optimasi threshold VADER

Pendekatan ini sejalan dengan yang dilakukan oleh jurnal [29], yang menunjukkan optimasi *threshold* pada VADER dapat meningkatkan akurasi klasifikasi pelabelan sentimen. Penelitian tersebut juga menyatakan pentingnya untuk penyesuaian ambang batas untuk mengurangi bias dan meningkatkan konsistensi yang dilakukan oleh model VADER.

3.2.6 Meta-classification model

Setelah model RoBERTa selesai dilatih dan ambang batas pada VADER telah dioptimalkan, langkah selanjutnya dalam penelitian ini adalah membangun model hybrid yang menggabungkan hasil prediksi dari keduanya. Tujuan dari pendekatan hybrid ini adalah untuk memanfaatkan keunggulan masing-masing

model. RoBERTa memiliki kemampuan memahami konteks kalimat secara mendalam melalui transformer-based architecture, sedangkan VADER unggul dalam menangani ekspresi sentimen informal dan simbolik yang umum digunakan di media sosial.

Tabel 3. 3 Jumlah data train atau input meta-classfier model

Label	Jumlah
Negatif	993
Netral	2.894
Positif	2.499

Proses penggabungan dilakukan menggunakan teknik *meta-classification*, di mana 70% dataset hasil prediksi dari kedua model digunakan sebagai fitur input untuk model klasifikasi akhir berbasis Logistic Regression dan 30% dari dataset digunakan sebagai bahan uji model. Dengan cara ini, model hybrid dapat mempelajari pola kombinasi terbaik dari dua prediktor untuk menghasilkan klasifikasi sentimen akhir yang lebih akurat.

Tabel 3. 4 Jumlah data uji meta-classifer model

Label	Jumlah
Negatif	426
Netral	1.240
Positif	1.071

Pendekatan ini didukung oleh penelitian sebelumnya, di mana kombinasi antara RoBERTa dan metode berbasis leksikon mampu menghasilkan performa yang lebih baik dibandingkan model tunggal [13]. Pada jurnal tersebut, integrasi RoBERTa dengan pendekatan VADER terbukti meningkatkan akurasi analisis sentimen terhadap ulasan produk dengan mengoptimalkan kekuatan masing-masing model.

3.2.7 Evaluate model

Evaluasi model adalah tahap penting dalam proses analisis sentimen karena menentukan seberapa baik model mampu memprediksi kelas sentimen secara akurat. Tujuan utama dari evaluasi ini adalah untuk mengukur performa model dalam mengklasifikasikan data ke dalam kategori sentimen, seperti positif, negatif,

atau netral. Beberapa metrik evaluasi yang umum digunakan dalam klasifikasi sentimen antara lain adalah *accuracy*, *precision*, *recall*, dan *F1-score*.

Menurut penelitian [30], metrik-metrik ini saling melengkapi untuk memberikan gambaran menyeluruh terhadap kinerja model. Dalam konteks data tidak seimbang, seperti pada analisis sentimen Twitter, F1-Score lebih direkomendasikan dibanding *accuracy* karena mampu menangkap keseimbangan antara *precision* dan *recall*. Metrik-metrik tersebut dijelaskan sebagai berikut:

1) Accuracy

Accuracy adalah metrik yang mengukur proporsi prediksi yang benar terhadap seluruh prediksi yang dilakukan model. Metrik ini sangat berguna ketika distribusi kelas seimbang. Namun, pada dataset tidak seimbang seperti sentimen netral yang dominan, *accuracy* saja tidak cukup untuk menilai performa model.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Keterangan:

TP : True Positive

TN : True Positive

FP : True Positive

TP : True Positive

2) Precision

Precision mengukur seberapa banyak dari hasil prediksi positif yang benar-benar merupakan data positif. Metrik ini penting ketika kesalahan prediksi positif harus diminimalisir (misalnya, menghindari false alarm).

$$Precision = \frac{TP}{TP + FP}$$

3) Recall

Recall mengukur seberapa banyak data positif yang berhasil ditemukan oleh model dari seluruh data positif yang sebenarnya. Metrik ini penting ketika semua instance positif harus terdeteksi (misalnya dalam analisis opini negatif terhadap suatu brand).

$$Recall = \frac{TP}{TP + FP}$$

4) F1-Score

F1-Score adalah rata-rata harmonis dari precision dan recall. F1 digunakan ketika diperlukan keseimbangan antara keduanya, khususnya pada dataset yang tidak seimbang. F1 memberikan gambaran yang lebih realistis daripada accuracy semata.

$$F1 - Score = 2 \times \frac{Presisi \times Recall}{Presisi + Recall}$$

Dalam studi tersebut, kelima metrik ini diterapkan secara bersamaan untuk memberikan evaluasi komprehensif pada sistem klasifikasi yang dibangun, dan hasilnya menunjukkan bahwa penggunaan F1-score memberikan pemahaman lebih baik terhadap performa model dalam mengatasi tantangan data yang tidak seimbang.

Pada tahap ini evaluasi performa dari masing-masing model yang telah dibangun. Evaluasi dilakukan terhadap tiga model utama, yaitu RoBERTa, VADER, dan Hybrid RoBERTa+VADER. Tujuannya adalah untuk mengetahui seberapa baik model dalam mengklasifikasikan sentimen tweet ke dalam tiga kategori (negatif, netral, dan positif).

Evaluasi dilakukan dengan menggunakan dataset berlabel dari TweetEval sebagai data uji. Metode evaluasi yang digunakan meliputi metrik akurasi, precision, recall, dan F1-score. Selain itu, confusion matrix juga digunakan untuk melihat persebaran prediksi yang benar dan salah dari setiap kelas sentimen.

Khusus untuk model VADER, dilakukan proses penyesuaian threshold untuk meningkatkan performanya. Hal ini bertujuan agar klasifikasi sentimen yang didasarkan pada skor compound dapat lebih presisi dan tidak terjebak dalam ambiguitas nilai netral.

Model hybrid RoBERTa+VADER juga diuji menggunakan metrik yang sama untuk melihat apakah penggabungan dua pendekatan ini benar-benar memberikan hasil yang lebih akurat dan seimbang di semua kelas. Evaluasi ini

sangat penting untuk memilih model terbaik yang nantinya akan diterapkan pada data sentimen publik.

3.2.8 Analyze Manchester United fan sentiment

Setelah model terbaik dipilih berdasarkan hasil evaluasi sebelumnya, tahap selanjutnya adalah menerapkan model tersebut untuk melakukan analisis sentimen terhadap tweet yang berkaitan dengan Manchester United dan keterlibatan INEOS. Data tweet ini diperoleh melalui proses scraping menggunakan alat *Tweet-Harvest*, dan tidak memiliki label sentimen. Oleh karena itu, data ini akan diprediksi sentimennya menggunakan model yang telah dilatih sebelumnya.

Model yang digunakan dalam penelitian ini adalah Hybrid RoBERTa dan VADER, karena model ini memberikan keseimbangan yang baik dalam mendeteksi sentimen positif, netral, dan negatif. Setiap tweet diproses dan dianalisis untuk menghasilkan label sentimen, yang kemudian digunakan untuk melihat persebaran opini publik terkait akuisisi sebagian saham Manchester United oleh INEOS dan Sir Jim Ratcliffe.

Hasil dari analisis ini divisualisasikan dalam bentuk diagram batang dan word cloud per kategori sentimen. Word cloud membantu menggambarkan kata-kata atau topik yang dominan pada masing-masing kategori, sementara diagram batang memberikan gambaran proporsi sentimen dari keseluruhan tweet yang dianalisis. Proses ini memungkinkan peneliti untuk menyimpulkan bagaimana reaksi yang tersebar pada platform Twitter terhadap perubahan kepemilikan tersebut.

3.3 Alat dan Bahan

Dalam penelitian ini, terdapat beberapa alat dan bahan yang digunakan untuk mendukung proses pengumpulan data, pengolahan, pelatihan model, serta visualisasi hasil. Adapun alat dan bahan tersebut dijelaskan sebagai berikut:

3.3.1 Alat

Alat yang digunakan dalam penelitian ini berupa perangkat keras dan perangkat lunak, yaitu:

- 1) Laptop/Komputer: Digunakan sebagai media utama untuk menjalankan seluruh proses penelitian, mulai dari pengolahan data hingga pelatihan

model. Adapun spesifikasi perangkat keras yang digunakan ialah prosesor Intel i7 generasi 10, RAM 16 GB, dan penyimpanan internal SSD 512GB.

- 2) Python: Bahasa pemrograman utama yang digunakan dalam penelitian ini. Python dipilih karena memiliki banyak pustaka (library) yang mendukung pengolahan data dan analisis sentimen. Python versi 3.9.21 digunakan dalam penelitian ini karena versi ini dapat berjalan baik dengan environment yang digunakan
- 3) Jupyter Notebook / VS Code: Code editor yang digunakan untuk menulis dan menjalankan kode Python secara interaktif, terutama saat tahap pengujian model dan visualisasi data. Penggunaan jupyter notebook pada vs code digunakan agar pemrosesan lebih cepat dibandingkan code editor yang berjalan berbasis cloud
- 4) TweetHarvest Repository: Merupakan alat open-source berbasis Python yang digunakan untuk melakukan pengambilan data (web scraping) dari Twitter menggunakan Twitter API. Repository ini memudahkan proses ekstraksi tweet yang berkaitan dengan Manchester United dan INEOS secara otomatis dan terstruktur.

3.3.2 Bahan

Bahan-bahan yang digunakan dalam penelitian ini meliputi:

- 1) Dataset TweetEval (sentiment): Dataset berlabel dari HuggingFace yang digunakan sebagai data pelatihan dan pengujian model. Dataset ini terdiri dari tweet berbahasa Inggris yang telah diklasifikasikan ke dalam tiga kategori sentimen: positif, netral, dan negatif.
- 2) Dataset Twitter Manchester United & INEOS: Dataset ini dikumpulkan dari Twitter menggunakan TweetHarvest, berisi opini publik pada platform twitter yang berkaitan dengan keterlibatan INEOS sebagai pemilik baru Manchester United. Dataset ini digunakan untuk pengujian lanjutan terhadap model setelah proses pelatihan selesai.
- 3) Python library: Beberapa pustaka yang digunakan dalam penelitian ini antara lain:
 - transformers – untuk mengakses model RoBERTa
 - scikit-learn – untuk proses pelatihan dan evaluasi model

- pandas, numpy – untuk manipulasi data
- matplotlib, seaborn, wordCloud – untuk visualisasi data
- nltk, vaderSentiment – untuk analisis sentimen berbasis leksikon

BAB IV HASIL DAN PEMBAHASAN

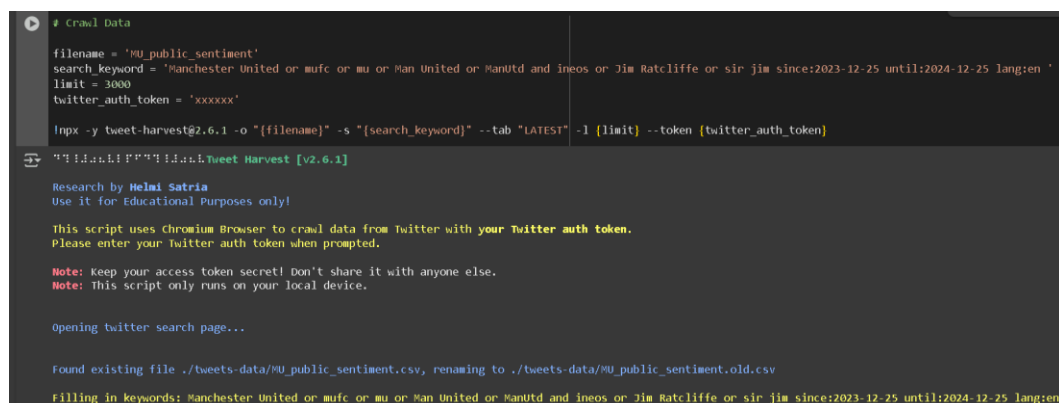
4.1 Gambaran Umum

Bab ini menyajikan hasil dari proses analisis sentimen terhadap keterlibatan INEOS dalam kepemilikan Manchester United yang telah dilakukan menggunakan dua pendekatan model yaitu, RoBERTa dan VADER. Proses ini mengacu pada tahapan metodologi yang dijelaskan pada Bab III, meliputi preprocessing, pembagian data, balancing, fine-tuning model RoBERTa, optimasi threshold VADER, hingga evaluasi model.

Data yang digunakan berasal dari Twitter dan telah melalui proses *scrapping*, pembersihan, pelabelan, dan pengelompokan. Hasil disajikan dalam bentuk tabel evaluasi, grafik akurasi, *F1-score*, serta *confusion matrix* dari masing-masing model.

4.2 Pengumpulan data

Sejalan dengan alur penelitian pada Bab III, tahap pertama pada penelitian ini ialah pengumpulan data. Pada penelitian ini untuk memperoleh data sentimen pada platfrom Twitter, repositori *Tweet-harvest* digunakan. Penggunaan repositori ini dipilih karena keefektifannya dalam memperoleh data dan cara penggunaanya yang mudah. Untuk melakukan *scrapping* menggunakan repositori tersebut cukup masukkan kata kunci yang ingin dicari seperti teknik *advance search* pada platfrom Twitter dan kode autentikasi akun Twitter. Dari teknik tersebut didapatkan data sentimen sejumlah 3.011 *tweet*.



```
# Crawl Data
filename = 'MU_public_sentiment'
search_keyword = 'Manchester United or mufc or mu or Man United or ManUtd and ineos or Jim Ratcliffe or sir jim since:2023-12-25 until:2024-12-25 lang:en '
limit = 3000
twitter_auth_token = 'xxxxxxxx'

Inpx -y tweet-harvest@2.6.1 -o "{filename}" -s "{search_keyword}" --tab "LATEST" -l {limit} --token {twitter_auth_token}

"Tweet Harvest [v2.6.1]"
Research by Helmi Satria
Use it for Educational Purposes only!

This script uses Chromium Browser to crawl data from Twitter with your Twitter auth token.
Please enter your Twitter auth token when prompted.

Note: Keep your access token secret! don't share it with anyone else.
Note: This script only runs on your local device.

opening twitter search page...

Found existing file ./tweets-data/MU_public_sentiment.csv, renaming to ./tweets-data/MU_public_sentiment.old.csv
Filling in keywords: Manchester United or mufc or mu or Man United or ManUtd and ineos or Jim Ratcliffe or sir jim since:2023-12-25 until:2024-12-25 lang:en
```

Gambar 4. 1 *Scrapping Tweet-harvest*

```

Your tweets saved to: /content/tweets-data/MU_public_sentiment.csv
Total tweets saved: 2963

-- Scrolling... (1)

Your tweets saved to: /content/tweets-data/MU_public_sentiment.csv
Total tweets saved: 2979

-- Scrolling... (1)

Your tweets saved to: /content/tweets-data/MU_public_sentiment.csv
Total tweets saved: 2993

-- Scrolling... (1) (2) (3) (4)

Your tweets saved to: /content/tweets-data/MU_public_sentiment.csv
Total tweets saved: 3011

--Taking a break, waiting for 10 seconds...
Got 3011 tweets, done scrolling...
":

```

Gambar 4. 2 Hasil scrapping data Tweet

Sedangkan untuk pengumpulan data train, dalam penelitian ini menggunakan modul *load_dataset* dari *library datasets* untuk memanggil dataset *tweet_eval/sentiment*. Dataset tersebut bersifat *open-source* yang dapat diakses melalui platform *Huggingface*. Dataset train digunakan sebagai bahan untuk mengevaluasi model. Didalam dataset tersebut terdapat 45.615 baris data terkumpul.

```

# Load dataset
dataset = load_dataset("tweet_eval", "sentiment")

# Konversi ke pandas untuk preprocessing lebih mudah
df = pd.DataFrame(dataset['train'])

# Mapping label: 0 = negative, 1 = neutral, 2 = positive
label_map = {0: "negative", 1: "neutral", 2: "positive"}
df["label_text"] = df["label"].map(label_map)

df.head()

```

Gambar 4. 3 Pengumpulan data pelatihan


4.2 Eksplorasi Data

Eksplorasi data dilakukan untuk memahami karakteristik data yang digunakan dalam pelatihan model dan data hasil crawling tweet terkait topik penelitian. Langkah ini bertujuan untuk melihat distribusi kelas, jumlah data, serta potensi bias yang dapat memengaruhi hasil analisis sentimen.

4.2.1 Eksplorasi Data Pelatihan

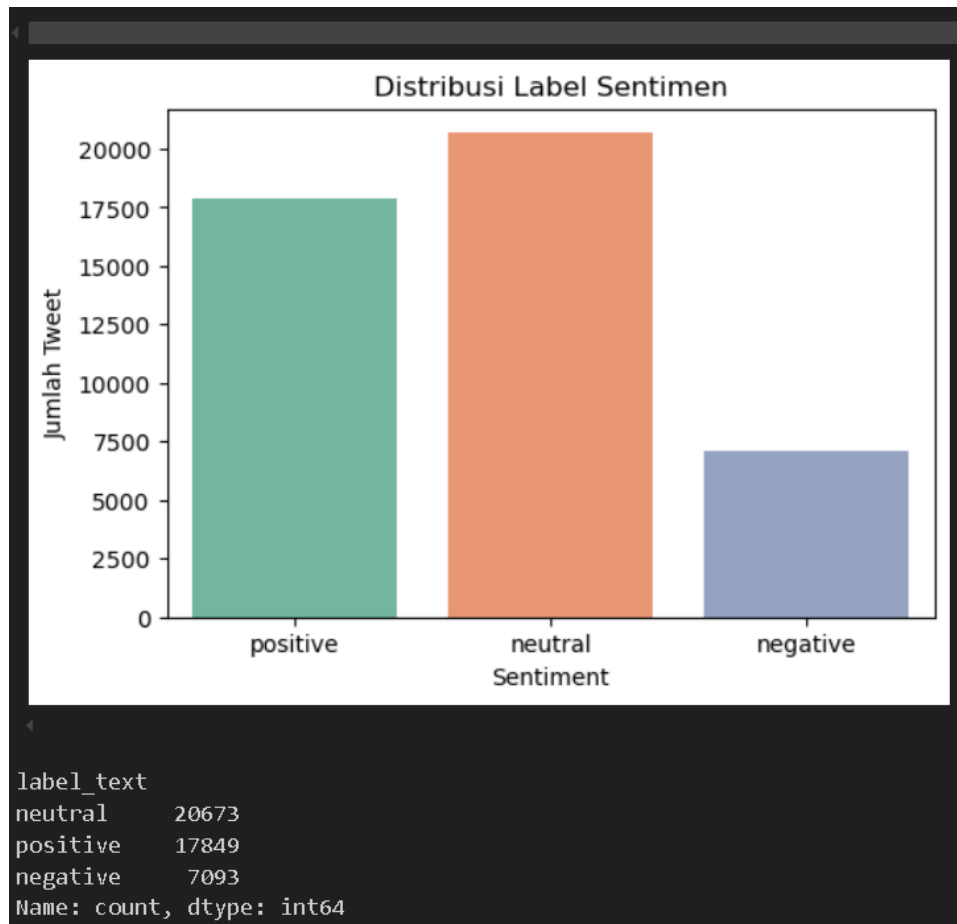
Data training yang digunakan dalam penelitian ini merupakan bagian dari dataset TweetEval/Sentiment, sebuah dataset benchmark yang umum digunakan dalam tugas analisis sentimen pada media sosial. Dataset ini telah memiliki label sentimen: positif, netral, dan negatif. Beberapa hasil eksplorasi data pelatihan model ialah sebagai berikut:

- 1) Jumlah Data: Dataset terdiri dari total 45.615 tweet, yang kemudian dibagi menjadi data latih, validasi, dan uji



Gambar 4. 4 Hasil Jumlah data training yang didapatkan

- 2) Distribusi Kelas: 45.615 tweet tersebut dibagi menjadi 3 label kelas yang dapat dilihat pada gambar 2.




Gambar 4. 5 Distribusi Label Sentimen Data Pelatihan

Jika divisualisasikan persebaran distribusi label sentimen tersebut menunjukkan, kelas neutral mendominasi jumlah data, diikuti oleh positive, sementara negative memiliki jumlah data paling sedikit. Grafik distribusi memperlihatkan bahwa frekuensi tweet netral hampir tiga kali lipat lebih banyak dibandingkan tweet negatif. Distribusi ini dapat memengaruhi performa model, terutama dalam mengenali sentimen kelas negatif. Oleh karena itu untuk mengurangi bias model, perlu dilakukannya strategi balancing data dan harus mempertimbangkan metrik seperti *F1-score* dan *recall*. Hal ini bertujuan agar model dapat belajar secara proporsional terhadap masing-masing kategori sentimen dan agar kinerja model tidak hanya dinilai berdasarkan akurasi keseluruhan yang bisa saja menyesatkan pada data tidak seimbang.


- 3) Panjang Teks: Rata-rata panjang tweet adalah 107 kata. Semua kelas sentimen memiliki distribusi panjang tweet yang relatif mirip, dengan

rentang interkuartil (IQR) yang berkisar antara 89 hingga 128 karakter. Ini menunjukkan bahwa secara umum, panjang tweet tidak jauh berbeda terlepas dari sentimennya. Semua kelas menunjukkan adanya outlier di bawah (tweet sangat pendek) dan beberapa outlier di atas (tweet sangat panjang). Ini wajar karena tweet di media sosial bisa sangat bervariasi, dari 1 kata hingga maksimal karakter yang diperbolehkan 200 pada postingan tweet.



Gambar 4. 6 Distribusi panjang tweet per kelas sentimen

- 4) WordCloud: Untuk memahami karakteristik isi teks pada masing-masing kategori sentimen, dilakukan eksplorasi visual menggunakan WordCloud. WordCloud menampilkan kata-kata yang paling sering muncul pada tweet yang dikategorikan ke dalam sentimen positif, netral, dan negatif.



Gambar 4. 7 WordCloud data pelatihan

Pada label positif, terlihat kata-kata seperti “love”, “see”, “excited”, dan “tomorrow” mendominasi, yang mencerminkan ekspresi antusiasme dan harapan. Sementara itu, label netral didominasi kata-kata umum seperti “think”, “get”, dan “know” yang tidak menunjukkan emosi kuat, menandakan bahwa tweet-tweet pada kategori ini bersifat informatif atau deskriptif. Pada label negatif, muncul kata-kata seperti “hate”, “bad”, “no”,


dan “want”, yang menandakan adanya ketidakpuasan atau emosi negatif dalam isi tweet.

Kata “user” dan “may” muncul merata di semua kategori karena merupakan hasil preprocessing (pengganti mention atau kata umum) dan tidak merepresentasikan sentimen secara langsung. Hasil eksplorasi ini menunjukkan bahwa terdapat perbedaan pola kata yang cukup mencolok di setiap kelas sentimen, yang dapat menjadi indikator awal dalam klasifikasi sentimen menggunakan model.

4.2.2 Eksplorasi Data Tweet

Data kedua berasal dari proses *scrapping* menggunakan repositori *Tweet-Harvest*, yang mengumpulkan tweet berdasarkan kata kunci seperti “INEOS Manchester United”, “Ratcliffe MUFC”, dan lainnya. Dataset ini belum memiliki label sentimen dan digunakan untuk evaluasi dan implementasi model. Hasil eksplorasi menunjukkan:

- 1) Jumlah Tweet: Berkumpul sekitar 3.011 tweet dalam rentang waktu 24 Desember 2023 hingga 25 Desember 2024
- 2) Panjang teks: Visualisasi distribusi panjang teks pada dataset tweet Manchester United menunjukkan bahwa tweet memiliki rentang panjang mulai dari sekitar 10 hingga batas maksimal 280 karakter. Pola distribusi bersifat bimodal, dengan dua puncak utama yang tampak pada kisaran panjang 80–100 karakter dan mendekati 260–280 karakter. Hal ini mengindikasikan bahwa sebagian besar pengguna Twitter menyampaikan pendapatnya dalam format ringkas, namun tidak sedikit pula yang memanfaatkan kapasitas maksimal karakter untuk mengekspresikan opini secara lebih detail.



Gambar 4. 8 Persebaran distribusi data tweet

Distribusi ini relatif merata tanpa adanya kemiringan ekstrem, menandakan bahwa model analisis sentimen yang digunakan perlu mampu menangani variasi panjang teks yang cukup lebar. Selain itu, tidak ditemukan banyak outlier di sisi panjang yang sangat pendek, yang berarti sebagian besar data berisi informasi yang cukup untuk dianalisis. Pola distribusi ini penting diperhatikan karena panjang teks dapat memengaruhi kualitas representasi fitur dalam model klasifikasi sentimen, khususnya pada model berbasis Transformer seperti RoBERTa yang sensitif terhadap konteks dan struktur kalimat yang kompleks.

- 3) WordCloud: Visualisasi WordCloud menunjukkan kata-kata yang paling sering muncul dalam dataset tweet yang berkaitan dengan Manchester United selama periode keterlibatan INEOS. Kata-kata seperti "Manchester", "United", "Jim", "Ratcliffe", dan "INEOS" mendominasi percakapan, mengindikasikan tingginya fokus publik terhadap proses akuisisi dan kepemilikan klub. Selain itu, istilah lain seperti "ownership", "club", "Glazer", dan "stake" menegaskan bahwa topik manajemen dan restrukturisasi menjadi perhatian utama warganet.



Gambar 4. 9 WordCloud data tweet

Kemunculan nama-nama tokoh seperti "Ten Hag", "Ferguson", dan kata kerja seperti "sack" atau "change" juga menunjukkan adanya diskusi yang cukup intens mengenai performa tim dan perubahan dalam struktur organisasi. WordCloud ini memberikan gambaran awal mengenai konteks dan arah opini publik terhadap perubahan yang terjadi di tubuh Manchester United, yang akan dianalisis lebih lanjut melalui pendekatan analisis sentimen.

4.3 Hasil Evaluasi Model RoBERTa

Setelah proses *balancing* dilakukan terhadap dataset (*oversampling*, *undersampling*, dan *original*), model RoBERTa di-finetune pada masing-masing variasi dataset. Evaluasi dilakukan menggunakan metrik akurasi, F1-score, precision, dan recall.

Tabel 4. 1Evaluasi fine-tuning RoBERTa pada 3 versi dataset

Dataset	Accuracy	F1-score	Precision	Recall
Original	0.72	0.71	0.71	0.71
Oversampling	0.72	0.70	0.70	0.71
Undersampling	0.69	0.68	0.67	0.72

Dari ketiga model, performa terbaik diperoleh dari model yang dilatih menggunakan dataset original (tanpa *balancing*), dengan nilai F1-score mencapai

71%. Hal ini menunjukkan bahwa RoBERTa cukup mampu menangani ketidakseimbangan data tanpa memerlukan teknik balancing tambahan.

4.4 Hasil Evaluasi Model VADER

Model VADER dievaluasi dengan menggunakan threshold default dan setelah dilakukan optimasi threshold.

Tabel 4. 2 Perbandingan threshold default dan dioptimalkan VADER

Threshold	Accuracy	F1-score	Precision	Recall
Default	0.54	0.52	0.53	0.56
Optimized	0.59	0.55	0.57	0.54

Tabel tersebut menunjukkan bahwa setelah threshold VADER dioptimalkan, terjadi peningkatan akurasi dari 54% menjadi 59%. Nilai precision juga meningkat dari 53% menjadi 57%, walaupun recall sedikit menurun.

4.5 Hasil Evaluasi Model Meta-Classification

Model meta-classifier dibangun dengan menggunakan hasil prediksi dari RoBERTa dan VADER sebagai input ke dalam algoritma klasifikasi lanjutan, yaitu Logistic Regression. Tujuan dari pendekatan ini adalah untuk mengintegrasikan kekuatan dua model yang berbeda dalam memproses sentimen teks. Setelah dilakukan pelatihan terhadap model Logistic Regression menggunakan prediksi RoBERTa dan VADER dari data pelatihan, model diuji untuk mengevaluasi performa klasifikasi.

Tabel 4. 3 Hasil evaluasi meta-classifier model

Kelas	Precision	Recall	F1-score	Support
Negative	0.53	0.69	0.60	426
Neutral	0.74	0.63	0.68	1.240
Positive	0.76	0.79	0.78	1.071
Accuracy			0.71	2.737
Macro avg	0.68	0.71	0.69	2.737
Weighted avg	0.72	0.71	0.71	2.737

Berdasarkan hasil evaluasi, model meta-classifier menghasilkan akurasi sebesar 0.71 dan weighted F1-score sebesar 0.71, yang mencerminkan performa

umum model dalam mengklasifikasikan ketiga kelas sentimen. Jika dihitung tanpa mempertimbangkan proporsi jumlah data per kelas, nilai macro average F1-score tercatat sebesar 0.69. Hal ini menunjukkan bahwa, secara rata-rata, kemampuan model dalam menyeimbangkan precision dan recall untuk masing-masing kelas cukup baik.

Secara spesifik, model menunjukkan performa terbaik pada kelas positive, dengan nilai F1-score sebesar 0.78, disusul oleh kelas neutral dengan F1-score 0.68, dan kelas negative dengan F1-score 0.60. Ini mengindikasikan bahwa model lebih mampu mengenali sentimen positif dan netral dibandingkan sentimen negatif.


4.6 Perbandingan ketiga model

Pada tahap ini, dilakukan perbandingan kinerja antara ketiga pendekatan model yang digunakan, yaitu RoBERTa, VADER, dan meta-classifier. Perbandingan didasarkan pada metrik evaluasi accuracy, F1-score, precision, dan recall.

Tabel 4. 4 Metrik ketiga model

Model	Accuracy	F1-score	Precision	Recall
RoBERTa	0.72	0.71	0.71	0.71
VADER	0.59	0.55	0.57	0.54
Meta-classifier	0.71	0.71	0.72	0.71

Dari hasil pengujian, model RoBERTa menunjukkan performa terbaik dengan F1-score tertinggi sebesar 0.71 ketika dilatih menggunakan dataset original (tanpa balancing). Meskipun model ini tidak menggunakan teknik balancing, kemampuannya dalam memahami konteks teks melalui arsitektur transformer terbukti mampu menangani ketidakseimbangan label dengan baik. Hal ini ditunjukkan pula dari distribusi prediksi yang relatif stabil, terutama pada kelas Positive dengan jumlah prediksi benar mencapai 2.821 tweet, sebagaimana terlihat pada confusion matrix.



Gambar 4. 10 Confusion Matrix ketiga model

Sementara itu, model VADER yang berbasis leksikon memberikan hasil yang lebih rendah. Bahkan setelah dilakukan optimasi threshold, model ini hanya mampu mencapai F1-score sebesar 0.55. VADER cenderung kesulitan dalam membedakan ekspresi netral dan negatif, yang ditunjukkan oleh banyaknya kesalahan klasifikasi antara kedua kelas tersebut. Meskipun demikian, kekuatan VADER tetap terletak pada kemampuannya menangkap sentimen eksplisit dan simbolik, seperti emoji atau ekspresi sederhana yang umum digunakan di media sosial.

Sebagai solusi untuk mengatasi keterbatasan masing-masing model, dibangunlah model Meta-classifier berbasis Logistic Regression yang menggabungkan hasil prediksi dari RoBERTa dan VADER sebagai input. Hasil evaluasi menunjukkan bahwa pendekatan ini mampu menghasilkan akurasi sebesar 0.71 dan weighted F1-score sebesar 0.71, dengan performa terbaik pada kelas Positive (F1-score = 0.78). Meta-classifier juga menunjukkan hasil yang lebih seimbang untuk seluruh kelas, dibandingkan kedua model sebelumnya.

Visualisasi confusion matrix dari ketiga model (Gambar 4.7) memperkuat analisis ini. RoBERTa sangat unggul dalam mengenali sentimen Positive, tetapi memiliki kelemahan dalam membedakan Neutral dan Negative. VADER menghasilkan klasifikasi yang lebih acak dengan kecenderungan kesalahan yang tinggi pada kelas Neutral, sementara Meta-classifier berhasil menyeimbangkan kinerja antar ketiga kelas dan memperbaiki kesalahan klasifikasi yang umum terjadi pada dua model sebelumnya.

Dengan mempertimbangkan metrik evaluasi dan distribusi klasifikasi dari confusion matrix, dapat disimpulkan bahwa Meta-classifier merupakan pendekatan terbaik dalam tugas klasifikasi sentimen ini, karena mampu mengintegrasikan kekuatan kontekstual dari RoBERTa dan fleksibilitas simbolik dari VADER secara sinergis.

4.7 Analisis Sentimen Manchester United terhadap Keterlibatan INEOS


Setelah seluruh proses pemodelan dan evaluasi dilakukan, tahap akhir dari penelitian ini adalah analisis terhadap hasil klasifikasi sentimen menggunakan model hybrid/meta-classifier yang merupakan penggabungan dari RoBERTa dan VADER. Model ini memberikan klasifikasi terhadap 3.011 tweet terkait keterlibatan INEOS dalam kepemilikan Manchester United.

Tabel 4. 5 Perbandingan prediksi model terhadap sentimen Manchester United

Sentimen	RoBERTa	VADER	Hybrid
Negative	853	198	898
Neutral	1.752	864	1.644
Positive	406	1.949	469
Total	3.011	3.011	3.011

Distribusi hasil klasifikasi sentimen menunjukkan bahwa mayoritas tweet diklasifikasikan ke dalam sentimen netral dengan jumlah 1.644 tweet (54,6%), diikuti oleh sentimen negatif sebanyak 898 tweet (29,8%), dan sentimen positif sebanyak 469 tweet (15,6%). Pola ini mengindikasikan bahwa sebagian besar publik cenderung memberikan respons yang netral terhadap isu ini, dengan kelompok yang memberikan reaksi negatif hampir dua kali lipat lebih besar dari kelompok yang bersentimen positif. Untuk mendapatkan pemahaman yang lebih


mendalam mengenai opini publik, berikut ini dijelaskan analisis isi pada masing-masing kelas sentimen:



Gambar 4. 11 Visualisasi perbandingan prediksi model terhadap sentimen Manchester United

4.7.1 Analisis sentimen positif

Sentimen positif mencerminkan harapan dan dukungan dari sebagian penggemar terhadap keterlibatan INEOS dan Sir Jim Ratcliffe dalam kepemilikan Manchester United. Tweet-tweet dengan sentimen ini umumnya berisi ekspresi optimisme terhadap masa depan klub, keyakinan akan adanya reformasi manajemen, serta apresiasi terhadap langkah-langkah yang telah atau akan diambil oleh pihak INEOS.



Gambar 4. 12 Visualisasi Wordcloud Positive sentimen data tweet

Banyak tweet positif memuji peran Sir Jim Ratcliffe dalam membawa perubahan di tubuh Manchester United. Kata-kata kunci yang sering muncul dalam tweet ini antara lain "Manchester United", "Sir Jim", "Ratcliffe", "INEOS", "decision", "plan", "club", "future", "team", dan "sporting director". Istilah-istilah tersebut mencerminkan optimisme terhadap arah baru yang akan diambil klub, khususnya dalam hal manajemen internal, rekrutmen pemain, dan visi jangka panjang.


Beberapa tweet juga menyebut nama-nama penting seperti Erik ten Hag dan Dan Ashworth, menunjukkan harapan publik terhadap kolaborasi kepemimpinan yang solid. Dominasi kata positif seperti "confirmed", "thank", "agreement", dan "announced" memperkuat gambaran bahwa publik menyambut baik proses transisi kepemilikan ini. Meskipun proporsi tweet positif tidak sebanyak kelas lainnya, analisis ini menegaskan bahwa ada segmen penggemar yang menaruh harapan besar terhadap masa depan klub di bawah keterlibatan INEOS.

4.7.2 Analisis sentimen netral

Sentimen netral merupakan kategori terbanyak dalam hasil klasifikasi, mencakup lebih dari separuh data uji. Tweet dengan sentimen ini biasanya menyampaikan informasi secara faktual tanpa memperlihatkan opini atau emosi yang kuat, baik positif maupun negatif. Banyak dari tweet ini berupa berita,

4.7.3 Analisis sentimen negatif

Sentimen negatif merupakan kategori kedua terbanyak, mencerminkan kekhawatiran dan ketidakpuasan publik terhadap akuisisi saham Manchester United oleh INEOS. Tweet-tweet ini berisi kritik terhadap proses transisi kepemilikan, keraguan terhadap komitmen jangka panjang INEOS, atau kekecewaan terhadap kondisi internal klub yang belum membaik.



Gambar 4. 14 Visualisasi Wordcloud Negative sentimen data tweet

Tweet-tweet dalam kategori negatif menampilkan berbagai ekspresi kekecewaan dan ketidakpuasan terhadap kepemimpinan baru di Manchester United. Kata-kata kunci yang menonjol seperti "problem", "sacked", "worse", "not happy", "unpopular decisions", "issue", dan "mediocre" mencerminkan kekhawatiran penggemar terhadap arah yang diambil klub di bawah kepemimpinan INEOS dan Sir Jim Ratcliffe.

Nama-nama seperti "Glazer", "Sir Jim", "INEOS", dan "Erik ten Hag" tetap menjadi pusat perhatian, menunjukkan bahwa skeptisisme yang ditujukan kepada manajemen sebelumnya masih terbawa hingga saat ini. Kata-kata seperti "confused", "ticket price", "financial", dan "protest" juga menunjukkan adanya kekhawatiran terhadap kebijakan klub yang dianggap lebih mengedepankan keuntungan finansial daripada performa tim di lapangan.

Beberapa frasa bernada tajam seperti "fuck", "not safe anymore", dan "worst" turut mengindikasikan tingkat frustrasi yang tinggi dari sebagian

pendukung. Secara umum, analisis ini menunjukkan bahwa meskipun ada upaya perubahan dalam kepemilikan dan manajemen, sebagian penggemar masih meragukan efektivitas perubahan tersebut dan merasa bahwa permasalahan struktural klub belum benar-benar terselesaikan.

BAB V PENUTUP

5.1 Kesimpulan

Penelitian ini bertujuan untuk menganalisis sentimen keterlibatan INEOS sebagai pemilik baru Manchester United melalui platform Twitter dengan pendekatan Natural Language Processing menggunakan model VADER, RoBERTa, dan meta-classifier yang berbasis pada Logistic Regression. Berdasarkan hasil analisis, dapat disimpulkan bahwa tujuan penelitian telah tercapai dan selaras dengan hasil yang diperoleh. Penelitian berhasil menjawab pertanyaan mengenai bagaimana persepsi publik terhadap kepemilikan baru Manchester United oleh INEOS, serta mengevaluasi performa dua model sentimen utama dan kombinasi keduanya.

Model RoBERTa menunjukkan performa yang unggul dengan F1-score sebesar 0.71, diikuti oleh meta-classifier yang mengintegrasikan hasil RoBERTa dan VADER, yang menghasilkan hasil stabil dengan akurasi dan F1-score sebesar 0.71. Sementara itu, model VADER, meskipun lebih sederhana, memiliki kelemahan dalam mengenali sentimen negatif dan netral secara akurat. Hasil akhir menunjukkan bahwa mayoritas sentimen penggemar adalah netral (54,6%), diikuti oleh negatif (29,8%) dan positif (15,6%). Ini mengindikasikan bahwa sebagian besar penggemar bersikap hati-hati terhadap perubahan kepemilikan, meskipun ada harapan maupun kekhawatiran dari sebagian kecil lainnya.

Masalah yang dibahas dalam penelitian ini mencakup aspek teknis pemodelan sentimen dan dampak manajerial kepemilikan terhadap opini publik, dan hasilnya mencerminkan manfaat yang signifikan secara teoritis dan praktis. Penelitian ini memberikan kontribusi dalam pengembangan teknik NLP untuk analisis opini publik, khususnya dalam konteks industri olahraga profesional. Selain itu, hasil penelitian memberikan wawasan strategis bagi manajemen Manchester United dan stakeholder dalam memahami persepsi penggemar dan potensi dampak reputasi yang muncul akibat keterlibatan pihak korporasi seperti INEOS.

5.2 Saran

Berikut beberapa saran berdasarkan hasil penelitian:

1. Untuk Manajemen Klub Manchester United

Disarankan agar keterlibatan INEOS dikomunikasikan secara terbuka dan strategis kepada publik untuk meningkatkan sentimen positif dan mengurangi keraguan penggemar.

2. Untuk Penelitian Selanjutnya

Dapat dilakukan perluasan data dengan mencakup tweet dalam berbagai bahasa agar mencerminkan sentimen global secara lebih representatif dan pengembangan model dapat dilakukan agar model dapat mengklasifikasi dataset dengan ambiguitas tinggi. Selain itu, integrasi dengan model NLP lainnya seperti XLNet bisa dieksplorasi.

3. Untuk Pengembangan Teknologi

Penggunaan hybrid model seperti meta-classifier terbukti efektif dan dapat diterapkan pada sektor lain untuk menganalisis persepsi publik, termasuk dalam bidang politik, kesehatan, atau ekonomi.

4. Untuk Akademisi dan Mahasiswa

Penelitian ini dapat dijadikan referensi metodologis dalam kombinasi pendekatan leksikal dan deep learning untuk studi analisis sentimen berbasis media sosial.

REFERENSI

- [1] C. M. Annur, “Survei Ipsos: Indonesia Punya Penggemar Sepak Bola Terbesar di Dunia,” Katadata.co.id, Dec. 08, 2022. <https://databoks.katadata.co.id/olahraga/statistik/522de0f585f0915/survei-ipsos-indonesia-punya-penggemar-sepak-bola-terbesar-di-dunia>
- [2] S. Palete, J. Sartika Djafar, and Syamsuddin, “Kontrak Pemain Sepakbola Profesional Di Indonesia...,” *Economics and Digital Business Review*, vol. 4, no. 1, pp. 544–550, 2023.
- [3] CNBC Indonesia, “Era Abramovich Kelar, Chelsea Dijual Rp 78 T ke Todd Boehly,” CNBC Indonesia, May 31, 2022. <https://www.cnbcindonesia.com/market/20220531132312-17-343220/era-abramovich-kelar-chelsea-dijual-rp-78-t-ke-todd-boehly>
- [4] D. R. Putra, M. M. Muchlis, and S. Z. A. Ghany, “Dampak Investasi Arab dalam Industri Klub Bola Manchester City,” *Jurnal Ekonomi dan Kewirausahaan West Science*, vol. 2, no. 02, pp. 234–239, Apr. 2024, doi: <https://doi.org/10.58812/jekws.v2i02.1038>.
- [5] Manchester United, “Club statement,” www.manutd.com, Dec. 24, 2023. <https://www.manutd.com/en/news/detail/man-utd-reaches-agreement-for-sir-jim-ratcliffe-to-acquire-25-per-cent-shareholding>.
- [6] E. Shakina, T. Gasparetto, and A. Barajas, “Football Fans’ Emotions: Uncertainty Against Brand Perception,” *Frontiers in Psychology*, vol. 11, no. 1, May 2020, doi: <https://doi.org/10.3389/fpsyg.2020.00659>.
- [7] M. Asshiddiqi and K. Lhaksmana, “Perbandingan Metode Decision Tree dan Support Vector Machine untuk Analisis Sentimen pada Instagram Mengenai Kinerja PSSI,” Dec. 2020.
- [8] A. Rohman, E. Utami, and Suwanto Raharjo, “Deteksi Kondisi Emosi pada Media Sosial Menggunakan Pendekatan Leksikon dan Natural Language Processing,” *Jurnal Eksplora Informatika*, vol. 9, no. 1, Sep. 2019, doi: <https://doi.org/10.30864/eksplora.v9i1.277>.
- [9] G. R. Narayanaswamy, “Exploiting BERT and RoBERTa to Improve Performance for Aspect Based Sentiment Analysis,” *ARROW@TU Dublin*,

2021. <https://doi.org/10.21427/3w9n-we77> (accessed Jan. 09, 2025).
- [10] A. M. Betsy, “Comparative Analysis of NLP Models for Sentiment Analysis,” in *Multidisciplinary Research in Academics: the Way Forward*, Dr. G. Ramesh V and Editorial Team *Global Perspectives on Transforming Academics through Research and Innovative Strategies*, Eds., Emerald Publishers, Jul. 2023.
 - [11] E. Amelia and I. Yustiana, “Analisis Sentimen Pada Ulasan Produk UNIQLO dengan Algoritma Naive Bayes,” *Jurnal Sains Komputer & Informatika (J-SAKTI)*, vol. 8, no. 1, pp. 141–148, Mar. 2024.
 - [12] D. Nurmadewi, Z. F. Jailani, and N. K. Srimanik, “Comparison of the Performance of the VADER and RoBERTa Algorithms on Twitter,” *SISTEMASI*, vol. 13, no. 4, pp. 1547–1547, Jul. 2024, doi: <https://doi.org/10.32520/stmsi.v13i4.4198>.
 - [13] B. Kumar, Sheetal, V. S. Badiger, and A. Ds. Jacintha, “Sentiment Analysis for Products Review Based on NLP Using lexicon-based Approach and Roberta,” Mar. 2024, pp. 1–6. doi: <https://doi.org/10.1109/IITCEE59897.2024.10468039>.
 - [14] M. Franceschi, J. Brocard, F. Follert, and J. Gouguet, “Determinants of football players’ valuation: A systematic review,” *Journal of Economic Surveys*, vol. 38, no. 3, pp. 577–600, Feb. 2023, doi: <https://doi.org/10.1111/joes.12552>.
 - [15] Mr. R. Manglik, *Natural Language Processing*. EduGorilla Publication, 2024.
 - [16] R. Safitri, N. Alfira, D. Tamitiadini, W. W. A. Dewi, and N. Febriani, *Analisis Sentimen*. Universitas Brawijaya Press, 2021.
 - [17] B. Liu, *Sentiment analysis: mining opinions, sentiments, and emotions*. Cambridge; New York: Cambridge University Press, 2020.
 - [18] D. Jurafsky and J. H. Martin, “Speech and Language Processing,” [web.stanford.edu](http://web.stanford.edu/~jurafsky/slp3), Jan. 12, 2025. <https://web.stanford.edu/~jurafsky/slp3>
 - [19] A. Vaswani et al., “Attention Is All You Need,” Cornell University, Jun. 12, 2017. <https://arxiv.org/abs/1706.03762>
 - [20] J. Lu et al., “SOFT: Softmax-free transformer with linear complexity,” in

- Advances in Neural Information Processing Systems 34 (NeurIPS 2021), M. Ranzato, A. Beygelzimer, Y. Dauphin, P. S. Liang, and J. W. Vaughan, Eds., Curran Associates, Inc., 2021, pp. 21297–21309. Available: https://proceedings.neurips.cc/paper_files/paper/2021/file/b1d10e7bafa4421218a51b1e1f1b0ba2-Paper.pdf
- [21] Gifari, Muhammad Khaifa, Lhaksmana, Kemas M, and Mahendra Dwifabri, P, “Sentiment analysis on movie review using ensemble stacking model,” 2021, pp. 1–5. doi: <https://doi.org/10.1109/ICADEIS52521.2021.9702088>.
 - [22] M. Wankhade, A. C. S. Rao, and C. Kulkarni, “A Survey on Sentiment Analysis Methods, Applications, and Challenges,” *Artificial Intelligence Review*, vol. 55, no. 55, Feb. 2022, doi: <https://doi.org/10.1007/s10462-022-10144-1>.
 - [23] H.-T. Duong and T.-A. Nguyen-Thi, “A review: preprocessing techniques and data augmentation for sentiment analysis,” *Computational Social Networks*, vol. 8, no. 1, Jan. 2021, doi: <https://doi.org/10.1186/s40649-020-00080-x>.
 - [24] Amira Samy Talaat, “Sentiment analysis classification system using hybrid BERT models,” *Journal of Big Data*, vol. 10, no. 1, Jun. 2023, doi: <https://doi.org/10.1186/s40537-023-00781-w>.
 - [25] M. S. I. Malik, A. Nazarova, M. M. Jamjoom, and D. I. Ignatov, “Multilingual hope speech detection: A Robust framework using transfer learning of fine-tuning RoBERTa model,” *Journal of King Saud University - Computer and Information Sciences*, vol. 35, no. 8, p. 101736, Sep. 2023, doi: <https://doi.org/10.1016/j.jksuci.2023.101736>.
 - [26] S. Henning and A. Friedrich, “Methods for addressing class imbalance in deep learning-based natural language processing - AIhub,” *AIhub*, 2023. https://aihub.org/2023/03/30/methods-for-addressing-class-imbalance-in-deep-learning-based-natural-language-processing/?utm_source=chatgpt.com (accessed Jul. 05, 2025).
 - [27] R. Haluska, J. Brabec, and T. Komarek, “Benchmark of Data Preprocessing Methods for Imbalanced Classification,” 2021 IEEE International

- Conference on Big Data (Big Data), pp. 2970–2979, Dec. 2022, doi: <https://doi.org/10.1109/bigdata55660.2022.10021118>.
- [28] Ramazan Mengi, Hritik Ghorpade, and Arjun Kakade, “Fine-tuning T5 and RoBERTa Models for Enhanced Text Summarization and Sentiment Analysis,” *The Great Lakes Botanist*, Dec. 2023, Available: https://www.researchgate.net/publication/376232167_Fine-tuning_T5_and_RoBERTa_Models_for_Enhanced_Text_Summarization_and_Sentiment_Analysis?enrichId=rgreq-73883098387d2f5ea27d69c11def71a4-XXX&enrichSource=Y292ZXJQYWdlOzM3NjIzMjE2NztBUzoxMTQzMtI4MTIwOTU0NTgyMEAxNzAxODAzMTA2OTI4&el=1_x_2
- [29] V. Nurcahyawati, Z. Mustaffa, and M. Khalaf, “Exceeding Manual Labeling: VADER Lexicon as an Accurate Alternative to Automatic Sentiment Classification,” *The International Arab Journal of Information Technology*, vol. 22, no. 2, 2025, doi: <https://doi.org/10.34028/iajit/22/2/2>.
- [30] H. Kaur, K. Navneet, and Sandhu, “Evaluating the Effectiveness of the Proposed System Using F1 Score, Recall, Accuracy, Precision and Loss Metrics Compared to Prior Techniques,” Sep. 2024.